StereoQueerEval: Klasifikasi Ujaran Kebencian terhadap Komunitas LGBTQIA+ dengan XLM-RoBERTa dan Qwen3.5-9B

Anonymous ACL submission

Ringkasan

Penelitian ini menyajikan penyelesaian Subtask B StereoQueerEval melalui klasifikasi komentar YouTube berbahasa Inggris, Italia, dan Belanda ke dalam kelas `no`, `yes_implicit`, dan `yes_explicit`. Pendekatan utama menyesuaikan Qwen3.5-9B dengan LoRA, menggunakan tiga pilihan bahasa *prompt*. XLM-RoBERTa Base digunakan sebagai pembanding pada pembagian data yang sama. Seluruh pilihan *prompt* Qwen menghasilkan *macro-F1* lebih tinggi daripada pembanding. Skor tertinggi pada pengujian internal adalah 0,719146 pada data Inggris, 0,7036 pada data Italia, dan 0,641522 pada data Belanda. Kesamaan bahasa *prompt* dan komentar belum memberikan hasil tertinggi secara konsisten. Kelas `yes_implicit` memperoleh F1 terendah pada kedua model.

1 Pendahuluan

Deteksi ujaran kebencian memerlukan pemahaman maksud pesan, termasuk bahasa berkode dan ungkapan tidak langsung (ElSherief et al., 2021). Pada komentar yang menargetkan komunitas LGBTQIA+, variasi bahasa dan konteks budaya menambah tantangan tersebut. Chan et al. (2024) menunjukkan bahwa penerjemahan komentar ke bahasa Inggris memberikan hasil beragam karena sebagian istilah dan ungkapan tidak diterjemahkan dengan tepat. Temuan ini mendukung penggunaan komentar dalam bahasa aslinya.

Penelitian terkait menggunakan gabungan BERT, RoBERTa, dan HateBERT untuk mengenali homofobia dan transfobia (Nozza, 2022). QUEEREOTYPES menyediakan anotasi stereotip dan ujaran kebencian pada data Italia (Cignarella et al., 2024). Chan et al. (2024) juga mengevaluasi GPT-3.5-turbo sebelum dan sesudah pelatihan berlabel, tetapi menggunakan dua kelas dan *weighted-F1*. Skornya tidak dibandingkan langsung dengan penelitian ini. Pada tugas penilaian tata bahasa, Behzad et al. (2024) menemukan perbedaan hasil antarbahasa *prompt*, yang menjadi pertimbangan untuk menguji pilihan bahasa pada klasifikasi.

Penelitian ini berfokus pada penyelesaian Subtask B StereoQueerEval dengan XLM-RoBERTa Base dan Qwen3.5-9B. Komentar dipertahankan dalam bahasa aslinya. Tiga pilihan bahasa *prompt* digunakan pada Qwen untuk memperoleh pengaturan klasifikasi yang sesuai. Hasil dianalisis berdasarkan bahasa data dan kelas pada *test* yang sama.

Nguyen et al. (2025) mengevaluasi lima model bahasa besar pada deteksi ujaran yang menyerang komunitas LGBTQIA+ tanpa pelatihan tambahan dan melaporkan bahwa kesalahan klasifikasi masih terjadi. Penelitian ini menggunakan pelatihan berlabel untuk menyesuaikan model pada tiga kategori StereoQueerEval. Fokusnya adalah menghasilkan label yang sesuai untuk setiap komentar, dengan mempertahankan perbedaan antara kelas `no`, `yes_implicit`, dan `yes_explicit`.

2 Deskripsi *Task*

SemEval-2027 Task 8: StereoQueerEval mengkaji stereotip dan ujaran kebencian terhadap komunitas LGBTQIA+.[1] Subtask B meminta klasifikasi komentar ke dalam tiga kelas: `no` untuk komentar tanpa ujaran kebencian, `yes_implicit` untuk kebencian yang disampaikan tidak langsung, dan `yes_explicit` untuk kebencian yang dinyatakan langsung (StereoQueerEval Organizers, 2026). Percobaan menggunakan bahasa Inggris (EN), Italia (IT), dan Belanda (NL). Teks komentar menjadi *input* model, tanpa judul, deskripsi video, atau anotasi dari *subtask* lain.

3 Metodologi

3.1 Model

XLM-RoBERTa adalah model *Transformer* multibahasa dengan arsitektur *encoder*. Prapelatihan-

[1] https://semeval.github.io/SemEval2027/tasks.html

nya menggunakan lebih dari 2 TB teks dari 100 bahasa melalui *masked language modeling*, yaitu memprediksi token yang disembunyikan berdasarkan konteksnya (Conneau et al., 2020). Varian Base selanjutnya disebut XLM-R.

Qwen3.5-9B merupakan model multibahasa dengan sekitar sembilan miliar parameter (Qwen Team, 2026). Komponen bahasanya memperkirakan token berikutnya berdasarkan konteks sebelumnya. Model dapat menghasilkan *output* teks sesuai *prompt* dalam format percakapan.

3.2 Penyiapan Data

Eksplorasi data atau *exploratory data analysis* (EDA) memeriksa distribusi kelas, kelengkapan kolom, keunikan ID, dan duplikasi. Prapemrosesan menggunakan normalisasi Unicode NFKC untuk menyeragamkan representasi karakter yang setara agar kesamaan teks dapat diperiksa secara konsisten (Unicode Consortium, 2026). Kapitalisasi, emoji, dan tanda baca dipertahankan. Komentar tidak diterjemahkan.

Pembagian dilakukan per bahasa dengan stratifikasi label dan pengelompokan konteks video, menggunakan *seed* 42. Targetnya 70% *train*, 10% *validation*, dan 20% *test*. Komentar dengan pasangan judul–deskripsi yang sama atau duplikat setelah normalisasi ditempatkan pada kelompok yang sama agar tidak terpisah antarbagian. Komentar kemudian ditokenisasi dan dipotong sesuai batas *input* masing-masing model.

3.3 Pelatihan, Prediksi, dan Evaluasi

XLM-R menggunakan lapisan klasifikasi untuk menghasilkan satu dari tiga label. Seluruh parameter diperbarui selama pelatihan. Bobot kelas dihitung hanya dari *train* untuk memperhatikan kelas dengan contoh lebih sedikit.

Penyesuaian Qwen menggunakan *Low-Rank Adaptation* (LoRA) dan *supervised fine-tuning* (SFT). LoRA mempertahankan bobot utama model dan memperbarui parameter tambahan berukuran kecil (Hu et al., 2021). Perhitungan kesalahan hanya dilakukan pada bagian *output*, tanpa menyertakan *prompt* dan komentar.

Prompt menjelaskan tiga kategori dan menegaskan bahwa penyebutan identitas LGBTQIA+ saja tidak cukup untuk menentukan kebencian. Pilihan bahasanya adalah Inggris, Italia, dan Belanda, tanpa contoh komentar berlabel. *Output* dipetakan menjadi angka 0 untuk `no`, 1 untuk `yes_explicit`, dan 2 untuk `yes_implicit`. Saat prediksi, jumlah log probabilitas setiap pilihan beserta penanda akhirnya dihitung. Pilihan dengan skor tertinggi menjadi label prediksi.

Metrik utama adalah *macro-F1*, yaitu rata-rata F1 ketiga kelas dengan bobot yang sama. F1 setiap kelas juga dilaporkan. Evaluasi pada akhir setiap *epoch* digunakan untuk memilih model dengan *macro-F1* tertinggi pada *validation*. Model terpilih dievaluasi pada *test* yang sama untuk kedua pendekatan.

F1 menggabungkan *precision*, yaitu proporsi prediksi suatu kelas yang benar, dan *recall*, yaitu proporsi contoh kelas tersebut yang berhasil dikenali. Penggunaan rata-rata antarkelas membantu menilai kemampuan model pada kelas yang lebih sedikit, sehingga skor tidak hanya didominasi kelas dengan jumlah komentar terbesar.

4 Rancangan Eksperimen

Dataset terdiri atas 7.627 komentar berlabel dari penyelenggara StereoQueerEval. Pengujian menggunakan pembagian internal data tersebut, sehingga hasil belum merupakan evaluasi resmi *shared task*. Judul dan deskripsi hanya digunakan untuk pengelompokan konteks saat pembagian.

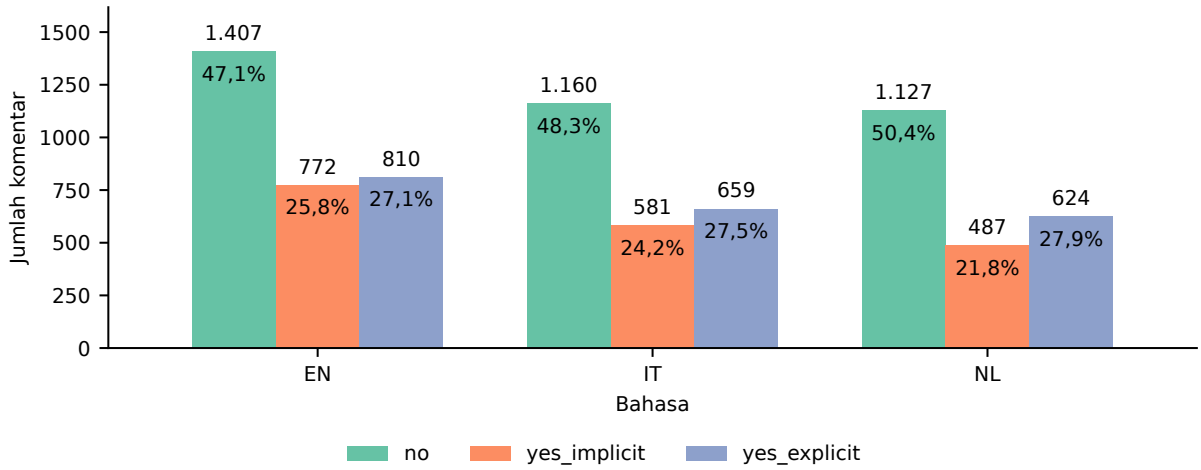
XLM-R dilatih satu kali per bahasa. Qwen dilatih pada sembilan pasangan bahasa komentar dan bahasa *prompt*, masing-masing dimulai dari model dasar yang sama dengan parameter LoRA baru. Bahasa *prompt* digunakan secara konsisten pada *train*, *validation*, dan *test*. Pelatihan dilakukan menggunakan Python dan PyTorch dengan GPU melalui platform Modal.

Tabel 1 merangkum konfigurasi kedua model. Keduanya menggunakan AdamW (Loshchilov and Hutter, 2019). Batas *input* Qwen memperhitungkan *prompt*, komentar, dan *output*. Pelatihan berhenti ketika skor *validation* tidak membaik sesuai ketentuan *early stopping*. Untuk pasangan yang diulang, hasil dilaporkan dari percobaan terbaru, tanpa memilih berdasarkan skor *test*.

5 Hasil dan Pembahasan

5.1 Eksplorasi Data (EDA)

Data terdiri atas 2.989 komentar Inggris, 2.400 Italia, dan 2.238 Belanda. Gambar 1 menunjukkan bahwa kelas `no` berjumlah paling banyak dan `yes_implicit` paling sedikit pada setiap bahasa. Ketidakseimbangan tersebut mendukung penggunaan *macro-F1* agar setiap kelas mendapat bobot evaluasi yang sama.



Gambar 1: Distribusi kelas sebelum pembagian. Jumlah komentar ditampilkan di atas batang dan persentase terhadap total per bahasa di dalam batang.

Pengaturan	XLM-R	Qwen
Fine-tuning	Seluruh parameter	SFT LoRA
Seed	42	42
Epoch maksimum	10	5
Learning rate	10^{-5}	10^{-4}
Weight decay	0,01	0,01
Batch size	32	16
Batas *input*	384 token	1.024 token
Scheduler	*Linear*	*Cosine*
Warmup	–	Sekitar 5% langkah
Early stopping	3	2
LoRA *rank*/*alpha*	–	16/32
LoRA *dropout*	–	0,05

Tabel 1: Konfigurasi pelatihan. *Early stopping* menyatakan jumlah evaluasi tanpa perbaikan pada *validation*.

Proporsi `no` mendekati separuh data pada ketiga bahasa, sedangkan `yes_implicit` berada pada kisaran 21,76%–25,83%. Data Belanda memiliki proporsi `yes_implicit` paling kecil. Distribusi ini perlu diperhatikan saat membaca hasil per kelas, tetapi belum cukup untuk menyimpulkan penyebab perbedaan kinerja antarbahasa. Distribusi label dan kemampuan mengenali setiap kelas dinilai secara terpisah.

5.2 Prapemrosesan dan Pembagian Data

Pemeriksaan tidak menemukan nilai kosong pada kolom yang dianalisis. Seluruh ID unik dan label sesuai tiga kelas. Satu duplikasi komentar pada data Italia memiliki label yang sama dan berada pada *train*. Seluruh komentar tetap teralokasi tanpa perubahan isi. Tidak ditemukan tumpang tindih ID, komentar ternormalisasi, atau pasangan judul–deskripsi nonkosong antarbagian. Jumlah hasil pembagian disajikan pada Tabel 2.

Data	*Train*	*Validation*	*Test*
EN	2.111	292	586
IT	1.699	220	481
NL	1.556	226	456

Tabel 2: Jumlah komentar setelah pembagian. Ketiga kelas hadir pada setiap bagian.

Hasil pembagian mendekati target 70:10:20, dengan jumlah aktual mengikuti kelompok komentar yang dipertahankan bersama. Dengan demikian, rasio tidak dipaksakan tepat apabila memerlukan pemisahan anggota kelompok. Pemeriksaan tumpang tindih membantu memastikan bahwa komentar yang sama tidak muncul pada bagian yang digunakan untuk pelatihan dan pengujian.

5.3 Hasil Klasifikasi Berdasarkan Bahasa

Seluruh pilihan *prompt* Qwen memperoleh *macro-F1* lebih tinggi daripada XLM-R, seperti ditunjukkan pada Tabel 3. Pada data Inggris, skor tertinggi diperoleh dengan *prompt* Inggris. Pada data Italia, skor tertinggi juga diperoleh dengan *prompt* Inggris, sedangkan pada data Belanda dengan *prompt* Belanda. Kesamaan bahasa *prompt* dan komentar belum memberikan hasil tertinggi secara konsisten.

Selisih skor Qwen tertinggi dan terendah adalah sekitar 0,0308 pada data Inggris, 0,0094 pada data Italia, dan 0,0116 pada data Belanda. Seluruh pilihan *prompt* menghasilkan skor lebih rendah pada data Belanda dibandingkan dua bahasa lain. Hasil tertinggi ini bersifat deskriptif, bukan pengaturan akhir yang dipilih berdasarkan *validation*. Perbedaan ukuran model, *tokenizer*, batas *input*, dan pe-

Data	XLM-R	Q-EN	Q-IT	Q-NL
EN	0.529052	**0.719146**	0.715757	0.688340
IT	0.574515	**0.7036**	0.694249	0.701449
NL	0.507678	0.629927	0.630810	**0.641522**

Tabel 3: *Macro-F1* pada *test*. Q-EN, Q-IT, dan Q-NL adalah Qwen dengan bahasa *prompt* EN, IT, dan NL. Nilai Qwen tertinggi per bahasa dicetak tebal.

latihan juga membuat selisih XLM-R dan Qwen belum dapat dikaitkan dengan satu komponen tertentu.

Jika dibandingkan dengan skor Qwen tertinggi yang teramati, selisih terhadap XLM-R adalah sekitar 0,1901 pada data Inggris, 0,1291 pada data Italia, dan 0,1338 pada data Belanda. Hasil tersebut mendukung penggunaan Qwen yang disesuaikan dengan data berlabel sebagai pendekatan penyelesaian pada pembagian internal ini. Namun, skor tunggal belum menunjukkan kestabilan keunggulan tersebut pada pembagian atau pengulangan lain.

5.4 Analisis Berdasarkan Kelas

Tabel 4 memperlihatkan bahwa `no` memperoleh F1 tertinggi dan `yes_implicit` terendah pada setiap pengaturan kedua model. Seluruh pilihan *prompt* Qwen menghasilkan F1 lebih tinggi daripada XLM-R untuk ketiga kelas pada bahasa data yang sama.

Pada data Inggris dan Italia, *prompt* Inggris memberikan F1 tertinggi untuk `no` dan `yes_implicit`, sedangkan *prompt* Italia tertinggi untuk `yes_explicit`. Pada data Belanda, *prompt* Belanda tertinggi untuk `no` dan `yes_explicit`, tetapi *prompt* Inggris tertinggi untuk `yes_implicit`. Dengan demikian, *prompt* dengan *macro-F1* tertinggi belum tentu terbaik pada setiap kelas.

Pada kelas `yes_implicit`, F1 Qwen berada pada rentang 0,5397–0,6172 untuk data Inggris, 0,5815–0,6127 untuk data Italia, dan 0,4806–0,5094 untuk data Belanda. Bahkan pilihan *prompt* tertinggi pada kelas tersebut masih menghasilkan skor lebih rendah daripada dua kelas lainnya dalam pengaturan yang sama. Perbaikan klasifikasi perlu memberi perhatian pada pembedaan kategori ini, dengan pemeriksaan contoh prediksi untuk mengetahui bentuk kesalahan yang terjadi.

6 Kesimpulan

Penyelesaian Subtask B StereoQueerEval menggunakan SFT LoRA pada Qwen3.5-9B menghasilkan skor lebih tinggi daripada XLM-R pada pengujian internal. Skor tertinggi adalah 0,719146 pada data Inggris, 0,7036 pada data Italia, dan 0,641522 pada data Belanda. Kesamaan bahasa *prompt* dan komentar belum konsisten memberikan hasil tertinggi. Pengembangan berikutnya perlu memperkuat klasifikasi `yes_implicit` dan memilih pengaturan melalui *validation*.

Keterbatasan

Percobaan menggunakan satu *seed* dan satu versi *prompt* per bahasa. Setiap pasangan Qwen melatih *adapter* terpisah, sehingga hasil tidak mengisolasi perbedaan bahasa *prompt* pada satu model terlatih. Variasi antarpengulangan belum diukur. Kesamaan *seed* juga belum menjamin hasil identik lintas versi perangkat lunak atau GPU (PyTorch Contributors, 2026). Reproduksi Qwen memerlukan kesamaan model dasar, *tokenizer*, *prompt*, pembagian data, dan konfigurasi pelatihan, dengan kebutuhan komputasi yang membatasi pengulangan pada perangkat lebih kecil.

Pengulangan dengan beberapa *seed* dan pelaporan rata-rata beserta variasi skor diperlukan untuk menilai reproduksibilitas Qwen. Selain konfigurasi pelatihan, versi model dasar dan perangkat lunak perlu dipertahankan agar perbandingan antarpengulangan dapat ditafsirkan dengan lebih jelas.

Hasil belum menggambarkan kinerja pada *test* resmi atau platform lain. Pasangan judul–deskripsi hanya menjadi pendekatan identitas video saat pembagian. Penyebab kesalahan pada masing-masing komentar masih memerlukan pemeriksaan langsung terhadap prediksi.

References

Shabnam Behzad, Amir Zeldes, and Nathan Schneider. 2024. To ask LLMs about English grammaticality, prompt them in a different language. In *Findings of the Association for Computational Linguistics: EMNLP 2024*, pages 15622–15634, Miami, Florida, USA. Association for Computational Linguistics.

Fai Leui Chan, Duke Nguyen, and Aditya Joshi. 2024. "is hate lost in translation?": Evaluation of multilingual LGBTQIA+ hate speech detection. In *Proceedings of the 22nd Annual Workshop of the Australasian Language Technology Association*, pages 146–152, Canberra, Australia. Association for Computational Linguistics.

Alessandra Teresa Cignarella, Manuela Sanguinetti, Simona Frenda, Andrea Marra, Cristina Bosco, and Valerio Basile. 2024. QUEEREOTYPES: A multisource Italian corpus of stereotypes towards LGBTQIA+ community members. In *Proceedings of the*

Data	Model	*Prompt*	no	yes_implicit	yes_explicit
EN	XLM-R	–	0.6569	0.4085	0.5217
EN	Qwen	EN	**0.8406**	**0.6172**	0.6996
EN	Qwen	IT	0.8229	0.5882	**0.7362**
EN	Qwen	NL	0.8250	0.5397	0.7003
IT	XLM-R	–	0.7056	0.4747	0.5432
IT	Qwen	EN	**0.7876**	**0.6127**	0.7104
IT	Qwen	IT	0.7786	0.5815	**0.7227**
IT	Qwen	NL	0.7806	0.6020	0.7217
NL	XLM-R	–	0.6742	0.3304	0.5185
NL	Qwen	EN	0.8118	**0.5094**	0.5686
NL	Qwen	IT	0.7908	0.4806	0.6210
NL	Qwen	NL	**0.8140**	0.4828	**0.6278**

Tabel 4: F1 setiap kelas pada *test*. Kolom *prompt* hanya berlaku untuk Qwen. Nilai Qwen tertinggi pada setiap kelas dan bahasa data dicetak tebal.

2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024), pages 13429–13441, Torino, Italia. ELRA and ICCL.

Alexis Conneau, Kartikay Khandelwal, Naman Goyal, Vishrav Chaudhary, Guillaume Wenzek, Francisco Guzmán, Edouard Grave, Myle Ott, Luke Zettlemoyer, and Veselin Stoyanov. 2020. Unsupervised cross-lingual representation learning at scale. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 8440–8451, Online. Association for Computational Linguistics.

Mai ElSherief, Caleb Ziems, David Muchlinski, Vaishnavi Anupindi, Jordyn Seybolt, Munmun De Choudhury, and Diyi Yang. 2021. Latent hatred: A benchmark for understanding implicit hate speech. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 345–363, Online and Punta Cana, Dominican Republic. Association for Computational Linguistics.

Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. 2021. LoRA: Low-rank adaptation of large language models. *Preprint*, arXiv:2106.09685.

Ilya Loshchilov and Frank Hutter. 2019. Decoupled weight decay regularization. In *International Conference on Learning Representations*.

Quoc-Toan Nguyen, Josh Nguyen, Van-Tuan Pham, and William John Teahan. 2025. Leveraging large language models in detecting anti-LGBTQIA+ user-generated texts. In *Proceedings of the Queer in AI Workshop*, pages 26–34, Hybrid format (in-person and virtual). Association for Computational Linguistics.

Debora Nozza. 2022. Nozza@LT-EDI-ACL2022: Ensemble modeling for homophobia and transphobia detection. In *Proceedings of the Second Workshop on Language Technology for Equality, Diversity and Inclusion*, pages 258–264, Dublin, Ireland. Association for Computational Linguistics.

PyTorch Contributors. 2026. Reproducibility. Dokumentasi PyTorch, diakses 27 Oktober 2026.

Qwen Team. 2026. Qwen3.5-9B: Model card. Dokumentasi checkpoint resmi, diakses 25 Oktober 2026.

StereoQueerEval Organizers. 2026. StereoQueerEval: Official repository and training data documentation for SemEval 2027. Dokumentasi daring, diakses 25 Oktober 2026.

Unicode Consortium. 2026. Unicode Standard Annex #15: Unicode Normalization Forms. Revision 58, 12 August 2026; accessed 27 October 2026.