StereoQueerEval: Klasifikasi Ujaran Kebencian terhadap Komunitas LGBTQIA+ dengan XLM-RoBERTa dan Qwen3.5-9B

Anonymous ACL submission

Ringkasan

Penelitian ini menyajikan penyelesaian Subtask B StereoQueerEval melalui klasifikasi komentar YouTube berbahasa Inggris, Italia, dan Belanda ke dalam kelas `no`, `yes_implicit`, dan `yes_explicit`. Pendekatan utama menyesuaikan Qwen3.5-9B dengan LoRA, menggunakan tiga pilihan bahasa *prompt*. XLM-RoBERTa Base digunakan sebagai pembanding pada pembagian data yang sama. Seluruh pilihan *prompt* Qwen menghasilkan *macro-F1* lebih tinggi daripada pembanding. Skor tertinggi pada pengujian internal adalah 0,719146 pada data Inggris, 0,7036 pada data Italia, dan 0,641522 pada data Belanda. Kesamaan bahasa *prompt* dan komentar belum memberikan hasil tertinggi secara konsisten. Kelas `yes_implicit` memperoleh F1 terendah pada kedua model.

1 Pendahuluan

Deteksi *hate speech* tidak hanya berkaitan dengan pengenalan kata-kata kasar. Pesan yang menyerang kelompok tertentu juga dapat disampaikan melalui ungkapan tersirat yang membutuhkan pemahaman konteks. ElSherief et al. (2021) menjelaskan bahwa bahasa berkode dan ungkapan tidak langsung menjadi tantangan dalam mendeteksi pesan tersebut. Perbedaan cara penyampaian membuat model perlu mengenali maksud pesan, bukan hanya kata-kata yang muncul di dalamnya.

Penelitian Chan et al. (2024) mengkaji deteksi *hate speech* terhadap komunitas LGBTQIA+ menggunakan GPT-3.5-turbo pada teks asli dan teks yang diterjemahkan ke bahasa Inggris. Penerjemahan tidak selalu membantu klasifikasi. Analisis kesalahan menunjukkan bahwa istilah *slang* dan ungkapan yang berkaitan dengan budaya tertentu tidak diterjemahkan dengan tepat. Hasil ini menjadi pertimbangan untuk mempertahankan bahasa asli komentar.

Salah satu hal yang belum diuji oleh Chan et al. (2024) adalah penggunaan bahasa *prompt* yang berbeda. Penelitian tersebut menggunakan *prompt* berbahasa Inggris, termasuk untuk data non-Inggris, dan menyarankan pengujian bahasa *prompt* yang sesuai dengan data beserta model lain. Saran ini menjadi dasar penggunaan Qwen dengan *prompt* Inggris, Italia, dan Belanda, baik pada bahasa komentar yang sama maupun berbeda.

Penelitian ini berfokus pada penyelesaian *Subtask B: Hate Speech Classification* dalam SemEval-2027 Task 8: StereoQueerEval. Komentar berbahasa Inggris, Italia, dan Belanda diklasifikasikan ke dalam kelas `no`, `yes_implicit`, dan `yes_explicit`. XLM-RoBERTa digunakan sebagai *baseline* karena prapelatihan multibahasanya mendukung berbagai tugas pemahaman bahasa lintas bahasa (Conneau et al., 2020). Hasilnya dibandingkan dengan Qwen pada *test* yang sama.

Tujuan penelitian ini adalah menyelesaikan klasifikasi dengan membandingkan XLM-RoBERTa dan Qwen melalui sembilan kombinasi bahasa data dan bahasa *prompt*. Tiga versi *prompt* memuat arahan dengan makna yang setara, sementara komentar tetap menggunakan bahasa aslinya. Hasil dianalisis untuk melihat apakah kesamaan bahasa *prompt* dan komentar memberikan skor lebih tinggi, sekaligus mengenali kelas yang masih sulit dibedakan.

2 Deskripsi *Task*

SemEval-2027 Task 8: StereoQueerEval mengkaji stereotip dan ujaran kebencian terhadap komunitas LGBTQIA+.[1] Subtask B meminta klasifikasi komentar ke dalam tiga kelas: `no` untuk komentar tanpa ujaran kebencian, `yes_implicit` untuk kebencian yang disampaikan tidak langsung, dan `yes_explicit` untuk kebencian yang dinyatakan langsung (StereoQueerEval Organizers, 2026). Percobaan menggunakan bahasa Inggris (EN), Italia

[1] https://semeval.github.io/SemEval2027/tasks.html

(IT), dan Belanda (NL). Teks komentar menjadi *input* model, tanpa judul, deskripsi video, atau anotasi dari *subtask* lain.

2.1 Penelitian Terkait

Nozza (2022) menggabungkan prediksi BERT, RoBERTa, dan HateBERT untuk mengenali homofobia dan transfobia pada komentar YouTube Inggris. QUEEREOTYPES menyediakan anotasi stereotip dan ujaran kebencian secara terpisah pada data Italia (Cignarella et al., 2024). Sementara itu, Chan et al. (2024) menggunakan GPT-3.5-turbo untuk klasifikasi dua kelas dan mengevaluasinya dengan *weighted-F1*. Penelitian ini membedakan tiga kelas menggunakan *macro-F1*, sehingga skornya tidak dibandingkan langsung dengan penelitian tersebut.

3 Metodologi

3.1 Model

XLM-RoBERTa adalah model *Transformer* multibahasa dengan arsitektur *encoder*. Prapelatihannya menggunakan lebih dari 2 TB teks dari 100 bahasa melalui *masked language modeling*, yaitu memprediksi token yang disembunyikan berdasarkan konteksnya (Conneau et al., 2020). Varian Base selanjutnya disebut XLM-R.

Qwen3.5-9B merupakan model multibahasa dengan sekitar sembilan miliar parameter (Qwen Team, 2026). Komponen bahasanya memperkirakan token berikutnya berdasarkan konteks sebelumnya. Model dapat menghasilkan *output* teks sesuai *prompt* dalam format percakapan.

3.2 Alur Analisis

3.2.1 Eksplorasi Data (EDA)

Eksplorasi data atau *exploratory data analysis* (EDA) memeriksa distribusi kelas, kelengkapan kolom, keunikan ID, dan duplikasi. Hasil pemeriksaan digunakan untuk memahami komposisi data sebelum pembagian.

3.2.2 Prapemrosesan dan Pembagian Data

Prapemrosesan menggunakan normalisasi Unicode NFKC untuk menyeragamkan representasi karakter yang setara agar kesamaan teks dapat diperiksa secara konsisten (Unicode Consortium, 2026). Kapitalisasi, emoji, dan tanda baca dipertahankan. Komentar tidak diterjemahkan.

Pembagian dilakukan per bahasa dengan stratifikasi label dan pengelompokan konteks video, menggunakan *seed* 42. Targetnya 70% *train*, 10% *validation*, dan 20% *test*. Komentar dengan pasangan judul–deskripsi yang sama atau duplikat setelah normalisasi ditempatkan pada kelompok yang sama agar tidak terpisah antarbagian. Komentar kemudian ditokenisasi dan dipotong sesuai batas *input* masing-masing model.

3.2.3 Pelatihan dan Prediksi

XLM-R menggunakan lapisan klasifikasi untuk menghasilkan satu dari tiga label. Seluruh parameter diperbarui selama pelatihan. Bobot kelas dihitung hanya dari *train* untuk memperhatikan kelas dengan contoh lebih sedikit.

Penyesuaian Qwen menggunakan *Low-Rank Adaptation* (LoRA) dan *supervised fine-tuning* (SFT). LoRA mempertahankan bobot utama model dan memperbarui parameter tambahan berukuran kecil (Hu et al., 2021). Perhitungan kesalahan hanya dilakukan pada bagian *output*, tanpa menyertakan *prompt* dan komentar.

Prompt menjelaskan tiga kategori dan menegaskan bahwa penyebutan identitas LGBTQIA+ saja tidak cukup untuk menentukan kebencian. Pilihan bahasanya adalah Inggris, Italia, dan Belanda, tanpa contoh komentar berlabel. *Output* dipetakan menjadi angka 0 untuk `no`, 1 untuk `yes_explicit`, dan 2 untuk `yes_implicit`. Saat prediksi, jumlah log probabilitas setiap pilihan beserta penanda akhirnya dihitung. Pilihan dengan skor tertinggi menjadi label prediksi.

3.2.4 Evaluasi Model

Evaluasi pada akhir setiap *epoch* digunakan untuk memilih model dengan *macro-F1* tertinggi pada *validation*. Model terpilih dievaluasi pada *test* yang sama untuk kedua pendekatan. Label yang benar pada *test* hanya digunakan untuk menghitung metrik evaluasi.

3.3 Metrik Evaluasi

Kinerja model dievaluasi menggunakan *macro-F1* sebagai metrik utama. Metrik ini memberikan bobot yang sama kepada kelas `no`, `yes_implicit`, dan `yes_explicit`, sehingga sesuai untuk mengevaluasi kinerja ketika jumlah contoh antarkelas berbeda. *Macro-F1* dihitung sebagai rata-rata F1 ketiga kelas.

F1 merupakan rata-rata harmonik *precision* dan *recall*. *Precision* menyatakan proporsi prediksi suatu kelas yang benar, sedangkan *recall* menyatakan proporsi contoh aktual kelas tersebut yang berhasil

dikenali. Perhitungannya dirumuskan sebagai:

$$F1_c = \frac{2P_cR_c}{P_c + R_c}, \tag{1}$$

$$\textit{Macro-F1} = \frac{1}{3}\sum_{c=1}^{3} F1_c. \tag{2}$$

Dengan P_c dan R_c masing-masing merupakan *precision* dan *recall* kelas c. *Macro-F1* pada *validation* digunakan untuk memilih *checkpoint* terbaik, sedangkan kinerja akhir dilaporkan pada *test* untuk setiap bahasa dan konfigurasi eksperimen. F1 per kelas juga disajikan untuk mengidentifikasi kategori yang masih sulit dikenali.

4 Rancangan Eksperimen

Dataset terdiri atas 7.627 komentar berlabel dari penyelenggara StereoQueerEval. Pengujian menggunakan pembagian internal data tersebut, sehingga hasil belum merupakan evaluasi resmi *shared task*. Judul dan deskripsi hanya digunakan untuk pengelompokan konteks saat pembagian.

XLM-R dilatih satu kali per bahasa. Qwen dilatih pada sembilan pasangan bahasa komentar dan bahasa *prompt*, masing-masing dimulai dari model dasar yang sama dengan parameter LoRA baru. Bahasa *prompt* digunakan secara konsisten pada *train*, *validation*, dan *test*. Pelatihan dilakukan menggunakan Python dan PyTorch dengan GPU melalui platform Modal.

Tabel 1 merangkum konfigurasi kedua model. Keduanya menggunakan AdamW (Loshchilov and Hutter, 2019). Batas *input* Qwen memperhitungkan *prompt*, komentar, dan *output*. Pelatihan berhenti ketika skor *validation* tidak membaik sesuai ketentuan *early stopping*. Untuk pasangan yang diulang, hasil dilaporkan dari percobaan terbaru, tanpa memilih berdasarkan skor *test*.

Pengaturan	XLM-R	Qwen
Fine-tuning	Seluruh parameter	SFT LoRA
Seed	42	42
Epoch maksimum	10	5
Learning rate	10^{-5}	10^{-4}
Weight decay	0,01	0,01
Batch size	32	16
Batas *input*	384 token	1.024 token
Scheduler	*Linear*	*Cosine*
Warmup	–	Sekitar 5% langkah
Early stopping	3	2
LoRA *rank*/*alpha*	–	16/32
LoRA *dropout*	–	0,05

Tabel 1: Konfigurasi pelatihan. *Early stopping* menyatakan jumlah evaluasi tanpa perbaikan pada *validation*.

Data	*Train*	*Validation*	*Test*
EN	2.111	292	586
IT	1.699	220	481
NL	1.556	226	456

Tabel 2: Jumlah komentar setelah pembagian. Ketiga kelas hadir pada setiap bagian.

5 Hasil dan Pembahasan

5.1 Eksplorasi Data (EDA)

Data terdiri atas 2.989 komentar Inggris, 2.400 Italia, dan 2.238 Belanda. Gambar 1 menunjukkan bahwa kelas `no` berjumlah paling banyak dan `yes_implicit` paling sedikit pada setiap bahasa. Ketidakseimbangan tersebut mendukung penggunaan *macro-F1* agar setiap kelas mendapat bobot evaluasi yang sama.

Proporsi `no` mendekati separuh data, sedangkan `yes_implicit` berada pada kisaran 21,76%–25,83%. Distribusi label perlu diperhatikan saat membaca F1 per kelas, tetapi belum menjelaskan penyebab perbedaan kinerja antarbahasa.

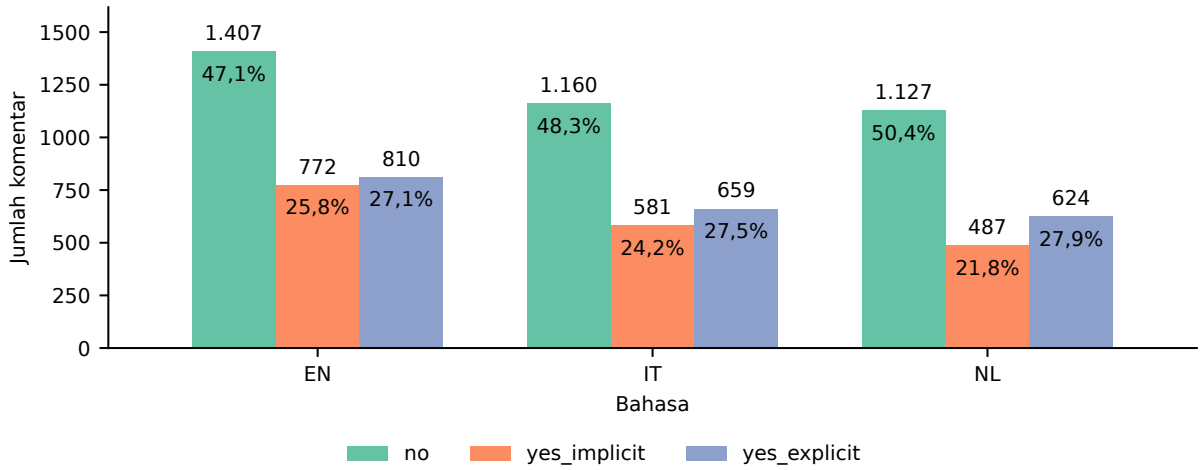
5.2 Prapemrosesan dan Pembagian Data

Pemeriksaan tidak menemukan nilai kosong pada kolom yang dianalisis. Seluruh ID unik dan label sesuai tiga kelas. Satu duplikasi komentar pada data Italia memiliki label yang sama dan berada pada *train*. Seluruh komentar tetap teralokasi tanpa perubahan isi. Tidak ditemukan tumpang tindih ID, komentar ternormalisasi, atau pasangan judul–deskripsi nonkosong antarbagian. Jumlah hasil pembagian disajikan pada Tabel 2.

Hasil pembagian mendekati target 70:10:20, dengan jumlah aktual mengikuti kelompok komentar yang dipertahankan bersama. Dengan demikian, rasio tidak dipaksakan tepat apabila memerlukan pemisahan anggota kelompok. Pemeriksaan tumpang tindih membantu memastikan bahwa komentar yang sama tidak muncul pada bagian yang digunakan untuk pelatihan dan pengujian.

5.3 Hasil Klasifikasi Berdasarkan Bahasa

Seluruh pilihan *prompt* Qwen memperoleh *macro-F1* lebih tinggi daripada XLM-R, seperti ditunjukkan pada Tabel 3. Pada data Inggris, skor tertinggi diperoleh dengan *prompt* Inggris. Pada data Italia, skor tertinggi juga diperoleh dengan *prompt* Inggris, sedangkan pada data Belanda dengan *prompt* Belanda. Kesamaan bahasa *prompt* dan komentar



Gambar 1: Distribusi kelas sebelum pembagian. Jumlah komentar ditampilkan di atas batang dan persentase terhadap total per bahasa di dalam batang.

Data	XLM-R	Q-EN	Q-IT	Q-NL
EN	0.529052	**0.719146**	0.715757	0.688340
IT	0.574515	**0.7036**	0.694249	0.701449
NL	0.507678	0.629927	0.630810	**0.641522**

Tabel 3: *Macro-F1* pada *test*. Q-EN, Q-IT, dan Q-NL adalah Qwen dengan bahasa *prompt* EN, IT, dan NL. Nilai Qwen tertinggi per bahasa dicetak tebal.

belum memberikan hasil tertinggi secara konsisten.

Selisih skor Qwen tertinggi dan terendah adalah sekitar 0,0308 pada data Inggris, 0,0094 pada data Italia, dan 0,0116 pada data Belanda. Seluruh pilihan *prompt* menghasilkan skor lebih rendah pada data Belanda dibandingkan dua bahasa lain. Hasil tertinggi ini bersifat deskriptif, bukan pengaturan akhir yang dipilih berdasarkan *validation*. Perbedaan ukuran model, *tokenizer*, batas *input*, dan pelatihan juga membuat selisih XLM-R dan Qwen belum dapat dikaitkan dengan satu komponen tertentu.

5.4 Analisis Berdasarkan Kelas

Tabel 4 memperlihatkan bahwa `no` memperoleh F1 tertinggi dan `yes_implicit` terendah pada setiap pengaturan kedua model. Seluruh pilihan *prompt* Qwen menghasilkan F1 lebih tinggi daripada XLM-R untuk ketiga kelas pada bahasa data yang sama.

Pada data Inggris dan Italia, *prompt* Inggris memberikan F1 tertinggi untuk `no` dan `yes_implicit`, sedangkan *prompt* Italia tertinggi untuk `yes_explicit`. Pada data Belanda, *prompt* Belanda tertinggi untuk `no` dan `yes_explicit`, tetapi *prompt* Inggris tertinggi untuk `yes_implicit`. Dengan demikian, *prompt* dengan *macro-F1* tertinggi belum tentu terbaik pada setiap kelas.

Pada kelas `yes_implicit`, F1 Qwen berada pada rentang 0,5397–0,6172 untuk data Inggris, 0,5815–0,6127 untuk data Italia, dan 0,4806–0,5094 untuk data Belanda. Bahkan pilihan *prompt* tertinggi pada kelas tersebut masih menghasilkan skor lebih rendah daripada dua kelas lainnya dalam pengaturan yang sama. Perbaikan klasifikasi perlu memberi perhatian pada pembedaan kategori ini, dengan pemeriksaan contoh prediksi untuk mengetahui bentuk kesalahan yang terjadi.

6 Kesimpulan

Penyelesaian Subtask B StereoQueerEval menggunakan SFT LoRA pada Qwen3.5-9B menghasilkan skor lebih tinggi daripada XLM-R pada pengujian internal. Skor tertinggi adalah 0,719146 pada data Inggris, 0,7036 pada data Italia, dan 0,641522 pada data Belanda. Kesamaan bahasa *prompt* dan komentar belum konsisten memberikan hasil tertinggi. Pengembangan berikutnya perlu memperkuat klasifikasi `yes_implicit` dan memilih pengaturan melalui *validation*.

Keterbatasan

Hasil berasal dari pengujian internal dengan satu *seed* dan satu versi *prompt* per bahasa, sehingga belum menunjukkan kinerja pada *test* resmi atau kestabilan antarpengulangan. Setiap pasangan Qwen melatih *adapter* terpisah, sehingga perbedaan skor tidak hanya menggambarkan bahasa *prompt*. Reproduksibilitas Qwen memerlukan kesamaan model, data, dan konfigurasi perangkat lunak. Kesamaan

Data	Model	*Prompt*	no	yes_implicit	yes_explicit
EN	XLM-R	–	0.6569	0.4085	0.5217
EN	Qwen	EN	**0.8406**	**0.6172**	0.6996
EN	Qwen	IT	0.8229	0.5882	**0.7362**
EN	Qwen	NL	0.8250	0.5397	0.7003
IT	XLM-R	–	0.7056	0.4747	0.5432
IT	Qwen	EN	**0.7876**	**0.6127**	0.7104
IT	Qwen	IT	0.7786	0.5815	**0.7227**
IT	Qwen	NL	0.7806	0.6020	0.7217
NL	XLM-R	–	0.6742	0.3304	0.5185
NL	Qwen	EN	0.8118	**0.5094**	0.5686
NL	Qwen	IT	0.7908	0.4806	0.6210
NL	Qwen	NL	**0.8140**	0.4828	**0.6278**

Tabel 4: F1 setiap kelas pada *test*. Kolom *prompt* hanya berlaku untuk Qwen. Nilai Qwen tertinggi pada setiap kelas dan bahasa data dicetak tebal.

seed belum menjamin hasil identik lintas lingkungan komputasi (PyTorch Contributors, 2026).

References

Fai Leui Chan, Duke Nguyen, and Aditya Joshi. 2024. "is hate lost in translation?": Evaluation of multilingual LGBTQIA+ hate speech detection. In *Proceedings of the 22nd Annual Workshop of the Australasian Language Technology Association*, pages 146–152, Canberra, Australia. Association for Computational Linguistics.

Alessandra Teresa Cignarella, Manuela Sanguinetti, Simona Frenda, Andrea Marra, Cristina Bosco, and Valerio Basile. 2024. QUEEREOTYPES: A multisource Italian corpus of stereotypes towards LGBTQIA+ community members. In *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, pages 13429–13441, Torino, Italia. ELRA and ICCL.

Alexis Conneau, Kartikay Khandelwal, Naman Goyal, Vishrav Chaudhary, Guillaume Wenzek, Francisco Guzmán, Edouard Grave, Myle Ott, Luke Zettlemoyer, and Veselin Stoyanov. 2020. Unsupervised cross-lingual representation learning at scale. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 8440–8451, Online. Association for Computational Linguistics.

Mai ElSherief, Caleb Ziems, David Muchlinski, Vaishnavi Anupindi, Jordyn Seybolt, Munmun De Choudhury, and Diyi Yang. 2021. Latent hatred: A benchmark for understanding implicit hate speech. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 345–363, Online and Punta Cana, Dominican Republic. Association for Computational Linguistics.

Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. 2021. LoRA: Low-rank adaptation of large language models. *Preprint*, arXiv:2106.09685.

Ilya Loshchilov and Frank Hutter. 2019. Decoupled weight decay regularization. In *International Conference on Learning Representations*.

Debora Nozza. 2022. Nozza@LT-EDI-ACL2022: Ensemble modeling for homophobia and transphobia detection. In *Proceedings of the Second Workshop on Language Technology for Equality, Diversity and Inclusion*, pages 258–264, Dublin, Ireland. Association for Computational Linguistics.

PyTorch Contributors. 2026. Reproducibility. Dokumentasi PyTorch, diakses 27 Oktober 2026.

Qwen Team. 2026. Qwen3.5-9B: Model card. Dokumentasi checkpoint resmi, diakses 25 Oktober 2026.

StereoQueerEval Organizers. 2026. StereoQueerEval: Official repository and training data documentation for SemEval 2027. Dokumentasi daring, diakses 25 Oktober 2026.

Unicode Consortium. 2026. Unicode Standard Annex #15: Unicode Normalization Forms. Revision 58, 12 August 2026; accessed 27 October 2026.