Action+1 at SemEval-2027 Task 8: *Fine-tuning* Qwen3.5-9B dengan *Prompt* Multibahasa untuk Klasifikasi *Hate Speech*

Aqila Khansa Hartanto **Rifki Martleo Alfiansyah**
Solo Bening Nuansa Nanditya **Wildan Abid Al Hanif**
Universitas Sebelas Maret
{aqilakhansahartanto, solobeningnuansan}@student.uns.ac.id

Abstrak

Deteksi *hate speech* multibahasa memerlukan pemahaman konteks. Penelitian ini menyelesaikan Subtask B StereoQueerEval melalui klasifikasi tiga kelas: `no`, `yes_implicit`, dan `yes_explicit`. Metodenya adalah *fine-tuning* Qwen3.5-9B dengan LoRA pada sembilan pasangan bahasa data dan *prompt*, dibandingkan dengan XLM-RoBERTa Base. Evaluasi menggunakan *macro-F1* pada pembagian internal data Inggris, Italia, dan Belanda yang sama. Seluruh pilihan *prompt* Qwen melampaui pembanding. Skor tertinggi adalah 0,719146 pada data Inggris, 0,7036 pada data Italia, dan 0,641522 pada data Belanda. Kesamaan bahasa *prompt* dan komentar belum konsisten memberikan hasil tertinggi, sedangkan `yes_implicit` memperoleh F1 terendah. Temuan ini mendukung penggunaan Qwen dengan LoRA dan perlunya memperbaiki klasifikasi `yes_implicit`.

1 Pendahuluan

Deteksi *hate speech* tidak hanya berkaitan dengan pengenalan kata-kata kasar. Pesan yang menyerang kelompok tertentu juga dapat disampaikan melalui ungkapan tersirat yang membutuhkan pemahaman konteks. ElSherief et al. (2021) menjelaskan bahwa bahasa berkode dan ungkapan tidak langsung menjadi tantangan dalam mendeteksi pesan tersebut. Perbedaan cara penyampaian membuat model perlu mengenali maksud pesan, bukan hanya kata-kata yang muncul di dalamnya.

Penelitian Chan et al. (2024) mengkaji deteksi *hate speech* terhadap komunitas LGBTQIA+ menggunakan GPT-3.5-turbo pada teks asli dan teks yang diterjemahkan ke bahasa Inggris. Peneliti menemukan bahwa sebagian kesalahan klasifikasi berkaitan dengan penerjemahan istilah *slang* dan ungkapan khas budaya yang kurang tepat. Temuan ini menjadi pertimbangan untuk mempertahankan bahasa asli komentar.

Salah satu hal yang belum diuji oleh Chan et al. (2024) adalah penggunaan bahasa *prompt* yang berbeda. Penelitian tersebut menggunakan *prompt* berbahasa Inggris, termasuk untuk data non-Inggris, dan menyarankan pengujian bahasa *prompt* yang sesuai dengan data beserta model lain. Saran ini menjadi dasar penggunaan Qwen dengan *prompt* Inggris, Italia, dan Belanda, baik pada bahasa komentar yang sama maupun berbeda.

Penelitian ini berfokus pada penyelesaian *Subtask B: Hate Speech Classification* dalam SemEval-2027 Task 8: StereoQueerEval. Komentar berbahasa Inggris, Italia, dan Belanda diklasifikasikan ke dalam kelas `no`, `yes_implicit`, dan `yes_explicit`. XLM-RoBERTa digunakan sebagai *baseline* karena model *pretrained* multibahasanya mendukung berbagai tugas lintas bahasa (Conneau et al., 2020), dan hasilnya dibandingkan dengan Qwen pada *test* yang sama.

Penelitian ini bertujuan menyelesaikan klasifikasi *hate speech* dengan membandingkan Qwen dan XLM-RoBERTa melalui sembilan kombinasi bahasa komentar dan bahasa *prompt*. Tiga versi *prompt* memiliki makna arahan yang setara, sementara komentar tetap menggunakan bahasa aslinya. Hasil evaluasi digunakan untuk menilai apakah kesesuaian bahasa *prompt* dan komentar memberikan *macro-F1* lebih tinggi, sekaligus mengidentifikasi kelas yang sulit diklasifikasikan.

2 Deskripsi *Task*

2.1 SemEval-2027 Task 8: StereoQueerEval

SemEval-2027 Task 8: StereoQueerEval mengkaji stereotip dan *hate speech* terhadap komunitas LGBTQIA+. Data berupa komentar YouTube beserta judul dan deskripsi video. Tiga *subtask* terdiri atas deteksi stereotip, klasifikasi *hate speech*, dan identifikasi target dan identitas LGBTQIA+.[1]

Penelitian ini menyelesaikan Subtask B melalui

[1] https://stereoqueereval.github.io/stereoqueereval/

tiga kelas: `no` untuk komentar tanpa *hate speech*, termasuk dukungan, `yes_implicit` untuk *hate speech* tersirat, dan `yes_explicit` untuk *hate speech* langsung (StereoQueerEval Organizers, 2026). Data Inggris (EN), Italia (IT), dan Belanda (NL) menggunakan kategori yang sama, sehingga hasil dapat dibandingkan per bahasa dan per kelas.

2.2 Penelitian Terkait

Penelitian klasifikasi *hate speech* masih menghadapi tantangan dalam mengenali kebencian implisit yang disampaikan melalui stereotip, bahasa berkode, dan ekspresi tidak langsung (ElSherief et al., 2021). Pada komunitas LGBTQIA+ dan konteks multibahasa, Chan et al. (2024) menggunakan GPT-3.5-turbo untuk klasifikasi dua kelas pada teks asli dan terjemahan bahasa Inggris, dan menemukan bahwa penerjemahan tidak selalu mempertahankan nuansa teks asli. Karena itu, penelitian ini mempertahankan bahasa asli komentar dan menggunakan tiga kelas dengan *macro-F1*, sehingga skornya tidak dibandingkan langsung dengan penelitian tersebut. XLM-R digunakan sebagai *baseline* karena representasi lintas bahasanya (Conneau et al., 2020).

Pada *Large Language Model* (LLM), Nguyen et al. (2025) mengevaluasi lima LLM tanpa pelatihan tambahan untuk mendeteksi ujaran yang menyerang komunitas LGBTQIA+ dan melaporkan bahwa kesalahan klasifikasi masih terjadi. Bahasa *prompt* juga dapat memengaruhi hasil: Behzad et al. (2024) menemukan perbedaan hasil antarbahasa *prompt* pada penilaian tata bahasa Inggris. Hal ini menjadi pertimbangan untuk menguji *prompt* berbahasa Inggris, Italia, dan Belanda, meskipun bukan bukti langsung pada deteksi ujaran kebencian.

3 Metodologi

3.1 XLM-RoBERTa Base

XLM-RoBERTa (XLM-R) merupakan model *Transformer* multibahasa dengan arsitektur *encoder* yang dilatih dengan *Masked Language Modeling* pada lebih dari 2 TB data CommonCrawl dari 100 bahasa, sehingga mampu membangun representasi lintas bahasa tanpa penerjemahan (Conneau et al., 2020). Varian Base, selanjutnya disebut XLM-R, memiliki 12 lapisan *Transformer*, 12 *attention heads*, dan representasi tersembunyi berdimensi 768. [2]

Setiap token *input* diubah menjadi representasi kontekstual oleh *encoder*. Representasi token klasifikasi dapat diteruskan ke lapisan klasifikasi untuk menghasilkan skor setiap kelas. Probabilitas kelas diperoleh melalui *softmax*.

3.2 Qwen3.5-9B

Qwen3.5-9B adalah model multibahasa dengan sekitar sembilan miliar parameter yang mendukung *input* teks dan visual (Qwen Team, 2026). Komponen bahasanya menghasilkan teks secara bertahap dengan memperkirakan token berikutnya berdasarkan konteks. *Prompt* menjelaskan konteks dan bentuk *output* dalam format percakapan.

Model ini memiliki 32 lapisan dan dimensi representasi 4.096. Arsitekturnya mengulang delapan kelompok yang masing-masing terdiri atas tiga lapisan *Gated DeltaNet* dan satu lapisan *Gated Attention*. Setiap lapisan dilengkapi *dense feed-forward network* (FFN). Token diproses melalui *embedding* dan susunan lapisan tersebut, kemudian normalisasi akhir dan *language modeling head* menghasilkan skor token berikutnya.

3.3 Alur Analisis

3.3.1 Eksplorasi Data (EDA)

Eksplorasi data atau *exploratory data analysis* (EDA) dilakukan pada *dataset* sebelum pembagian. Pemeriksaan meliputi jumlah komentar pada setiap bahasa dan kelas, kelengkapan kolom, keunikan ID, dan duplikasi komentar. Visualisasi distribusi kelas digunakan untuk memahami ketidakseimbangan label.

3.3.2 Prapemrosesan dan Pembagian Data

Prapemrosesan menggunakan normalisasi Unicode NFKC untuk menyeragamkan representasi karakter yang setara agar kesamaan teks diperiksa secara konsisten (Unicode Consortium, 2026). Kapitalisasi, emoji, dan tanda baca dipertahankan. Komentar tidak diterjemahkan.

Pembagian dilakukan per bahasa dengan stratifikasi label dan pengelompokan konteks video. Targetnya 70% *train*, 10% *validation*, dan 20% *test*. Komentar dengan pasangan judul–deskripsi yang sama atau duplikat setelah normalisasi ditempatkan pada kelompok yang sama agar tidak terpisah antarbagian. Komentar kemudian ditokenisasi dan dipotong sesuai batas *input* masing-masing model.

[2] https://huggingface.co/FacebookAI/xlm-roberta-base/blob/main/config.json

Pada Qwen, ruang untuk *prompt* dan *output* tetap disediakan.

3.3.3 Pelatihan dan Prediksi

Pada XLM-R, representasi teks diteruskan ke lapisan klasifikasi untuk menentukan satu dari tiga label. Seluruh parameter model dan lapisan klasifikasi diperbarui menggunakan *train*. Bobot kelas dihitung dari jumlah contoh pada *train* agar kelas yang lebih sedikit mendapat perhatian dalam perhitungan kesalahan.

Fine-tuning Qwen menggunakan LoRA dan *supervised fine-tuning* (SFT). SFT menggunakan pasangan *input* dan *output* yang benar, sedangkan LoRA mempertahankan bobot utama model dan memperbarui parameter tambahan berukuran kecil (Hu et al., 2021). Perhitungan kesalahan hanya dilakukan pada bagian *output*, tanpa menyertakan *prompt* dan komentar.

Prompt menjelaskan ketiga kategori dan menegaskan bahwa penyebutan identitas LGBTQIA+ saja tidak cukup untuk menganggap komentar sebagai kebencian. Tersedia tiga pilihan bahasa *prompt*, yaitu Inggris, Italia, dan Belanda, tanpa contoh komentar berlabel. *Output* berupa satu angka: 0 untuk `no`, 1 untuk `yes_explicit`, dan 2 untuk `yes_implicit`. Komentar tetap menggunakan bahasa aslinya. Nama penanda bahasa dan komentar dalam format *input* ditulis dalam bahasa Inggris pada seluruh pilihan *prompt*.

Saat prediksi, Qwen menghitung jumlah log probabilitas setiap pilihan *output* dengan penanda akhirnya. Pilihan dengan skor tertinggi menjadi label prediksi. Dengan aturan ini, *output* selalu berupa salah satu dari tiga kategori.

3.3.4 Evaluasi Model

Model dengan *macro-F1* tertinggi pada *validation* dipilih setelah evaluasi setiap *epoch*. Label prediksi dibandingkan dengan label yang benar pada *test* yang sama untuk kedua pendekatan. Hasil dilaporkan per bahasa dan per kelas. Pengujian merupakan evaluasi internal, bukan evaluasi pada *test* resmi.

3.4 Metrik Evaluasi

Kinerja model dievaluasi menggunakan *macro-F1* sebagai metrik utama. Metrik ini memberikan bobot yang sama kepada kelas `no`, `yes_implicit`, dan `yes_explicit`, sehingga sesuai untuk mengevaluasi kinerja ketika jumlah contoh antarkelas berbeda. *Macro-F1* dihitung sebagai rata-rata F1 ketiga kelas.

Pengaturan	XLM-R	Qwen
Fine-tuning	Seluruh parameter	SFT LoRA
Seed	42	42
Epoch maksimum	10	5
Learning rate	10^{-5}	10^{-4}
Weight decay	0,01	0,01
Batch size	32	16
Input maksimum	384 token	1.024 token
Scheduler	*Linear*	*Cosine*
Warmup	–	5%
Early stopping	3	2
LoRA r/α	–	16/32
LoRA *dropout*	–	0,05

Tabel 1: Konfigurasi *fine-tuning* kedua model. *Early stopping* menyatakan jumlah evaluasi tanpa perbaikan.

F1 merupakan rata-rata harmonik *precision* dan *recall*. *Precision* menyatakan proporsi prediksi suatu kelas yang benar, sedangkan *recall* menyatakan proporsi contoh aktual kelas tersebut yang berhasil dikenali. Perhitungannya dirumuskan sebagai:

$$F1_c = \frac{2P_cR_c}{P_c + R_c}, \tag{1}$$

$$\textit{Macro-F1} = \frac{1}{3}\sum_{c=1}^{3} F1_c. \tag{2}$$

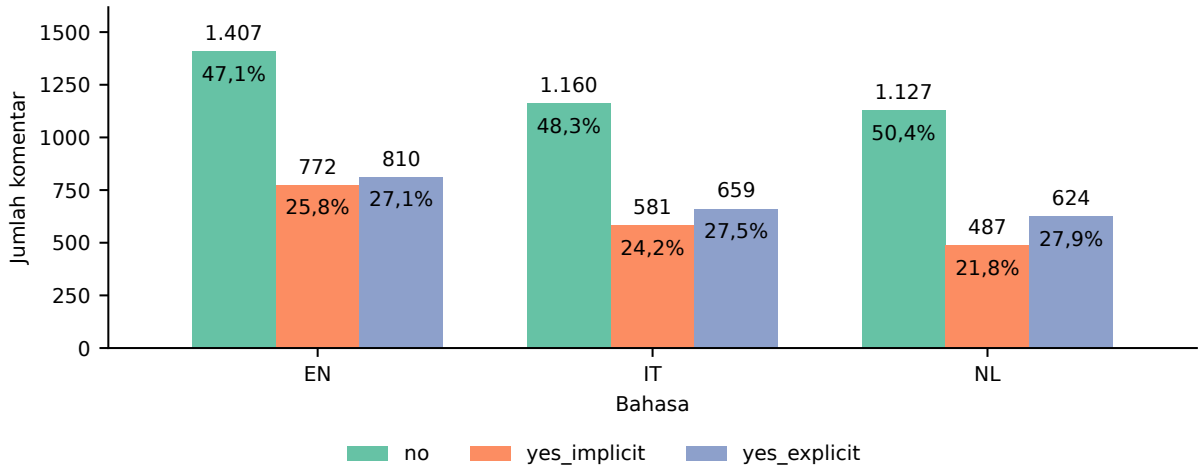
P_c dan R_c masing-masing menyatakan *precision* dan *recall* kelas c. *Macro-F1* pada *validation* digunakan untuk memilih *checkpoint* terbaik, sedangkan kinerja akhir dilaporkan pada *test* untuk setiap bahasa dan konfigurasi eksperimen. F1 per kelas juga disajikan untuk mengidentifikasi kategori yang masih sulit dikenali.

4 Rancangan Eksperimen

Dataset terdiri atas 7.627 komentar berlabel dari penyelenggara StereoQueerEval. Pengujian menggunakan pembagian internal data tersebut, sehingga hasil belum merupakan evaluasi resmi *shared task*. Judul dan deskripsi hanya digunakan untuk pengelompokan konteks saat pembagian.

XLM-R dilatih satu kali per bahasa. Qwen dilatih pada sembilan pasangan bahasa komentar dan bahasa *prompt*, masing-masing dimulai dari model dasar yang sama dengan parameter LoRA baru. Bahasa *prompt* digunakan secara konsisten pada *train*, *validation*, dan *test*. Pelatihan dilakukan menggunakan Python dan PyTorch dengan GPU melalui platform Modal.

Tabel 1 merangkum konfigurasi kedua model. Keduanya menggunakan AdamW (Loshchilov and



Gambar 1: Distribusi kelas sebelum pembagian. Jumlah ditampilkan di atas batang dan persentase terhadap total per bahasa di dalam batang.

Hutter, 2019). Batas *input* Qwen memperhitungkan *prompt*, komentar, dan *output*. Pelatihan berhenti ketika skor *validation* tidak membaik sesuai ketentuan *early stopping*.

5 Hasil dan Pembahasan

5.1 Eksplorasi Data

Data terdiri atas 2.989 komentar Inggris, 2.400 Italia, dan 2.238 Belanda. Gambar 1 menunjukkan bahwa kelas `no` berjumlah paling banyak dan `yes_implicit` paling sedikit pada setiap bahasa. Ketidakseimbangan tersebut mendukung penggunaan *macro-F1* agar setiap kelas mendapat bobot evaluasi yang sama.

Proporsi `no` mendekati separuh data, sedangkan `yes_implicit` berada pada kisaran 21,76%–25,83%. Distribusi label perlu diperhatikan saat membaca F1 per kelas, tetapi belum menjelaskan penyebab perbedaan kinerja antarbahasa. Pada XLM-R, bobot kelas untuk pelatihan dihitung hanya dari *train* masing-masing bahasa.

5.2 Prapemrosesan dan Pembagian Data

Tidak ditemukan nilai kosong pada kolom yang dianalisis. Seluruh ID unik dan label sesuai tiga kelas. Satu komentar duplikat pada data Italia memiliki label yang sama dan berada pada *train*. Seluruh komentar tetap digunakan tanpa perubahan isi.

Pembagian mempertahankan kelompok komentar pada bagian yang sama, sehingga proporsinya mendekati 70:10:20 (Tabel 2). Tidak ditemukan tumpang tindih ID, komentar ternormalisasi, atau pasangan judul–deskripsi nonkosong antarbagian.

Bahasa	Kelas	*Train*	*Validation*	*Test*
EN	`no`	983	147	277
EN	`yes_implicit`	546	70	156
EN	`yes_explicit`	582	75	153
EN	Total	2.111	292	586
IT	`no`	822	105	233
IT	`yes_implicit`	401	56	124
IT	`yes_explicit`	476	59	124
IT	Total	1.699	220	481
NL	`no`	784	109	234
NL	`yes_implicit`	335	55	97
NL	`yes_explicit`	437	62	125
NL	Total	1.556	226	456

Tabel 2: Jumlah komentar setiap kelas pada *train*, *validation*, dan *test* setelah pembagian.

		Qwen3.5-9B		
Data	XLM-R	EN	IT	NL
EN	0,529052	**0,719146**	0,715757	0,688340
IT	0,574515	**0,7036**	0,694249	0,701449
NL	0,507678	0,629927	0,630810	**0,641522**

Tabel 3: *Macro-F1* pada *test*. Kolom EN, IT, dan NL pada Qwen menunjukkan bahasa *prompt*. Nilai Qwen tertinggi per bahasa data dicetak tebal.

5.3 Evaluasi dan Perbandingan Model

Evaluasi membandingkan XLM-R yang dilatih per bahasa dengan Qwen setelah SFT pada sembilan pasangan bahasa data dan *prompt*. Semua pilihan *prompt* Qwen menghasilkan *macro-F1* lebih tinggi pada *test* yang sama (Tabel 3). Skor tertinggi yang teramati bersifat deskriptif, bukan pengaturan akhir yang dipilih melalui *validation*.

Selisih skor Qwen tertinggi terhadap XLM-R

Data	Model	*Prompt*	no	yes_implicit	yes_explicit
EN	XLM-R	–	0.6569	0.4085	0.5217
EN	Qwen	EN	**0.8406**	**0.6172**	0.6996
EN	Qwen	IT	0.8229	0.5882	**0.7362**
EN	Qwen	NL	0.8250	0.5397	0.7003
IT	XLM-R	–	0.7056	0.4747	0.5432
IT	Qwen	EN	**0.7876**	**0.6127**	0.7104
IT	Qwen	IT	0.7786	0.5815	**0.7227**
IT	Qwen	NL	0.7806	0.6020	0.7217
NL	XLM-R	–	0.6742	0.3304	0.5185
NL	Qwen	EN	0.8118	**0.5094**	0.5686
NL	Qwen	IT	0.7908	0.4806	0.6210
NL	Qwen	NL	**0.8140**	0.4828	**0.6278**

Tabel 4: F1 setiap kelas pada pengujian internal. Nilai Qwen tertinggi per kelas dan bahasa data dicetak tebal.

adalah sekitar 0,1901 pada data Inggris, 0,1291 pada data Italia, dan 0,1338 pada data Belanda. Kedua model dievaluasi pada *test* yang sama. Namun, ukuran model, *tokenizer*, batas *input*, dan cara pelatihannya berbeda. Oleh karena itu, selisih skor belum dapat dikaitkan dengan satu komponen tertentu.

Pada data Inggris, *prompt* Inggris memberikan skor tertinggi, diikuti Italia dan Belanda. Selisih skor tertinggi dan terendah sekitar 0,0308. Skor *prompt* Inggris (0,719146) dan Italia (0,715757) berdekatan.

Pada data Italia, *prompt* Inggris memperoleh skor tertinggi, diikuti Belanda dan Italia, dengan rentang skor 0,694249–0,7036. Bahasa *prompt* yang sama dengan komentar belum memberikan skor tertinggi.

Pada data Belanda, *prompt* Belanda memberikan skor tertinggi, diikuti Italia dan Inggris, dengan rentang 0,629927–0,641522. Seluruh pilihan menghasilkan skor lebih rendah daripada dua bahasa lain. Kesamaan bahasa *prompt* dan komentar belum konsisten memberikan skor tertinggi, dan hasil belum menjelaskan penyebab perbedaan antarbahasa.

5.4 Analisis Berdasarkan Kelas

Tabel 4 menyajikan F1 setiap kelas untuk XLM-R dan seluruh kombinasi bahasa data dengan *prompt* Qwen. Kelas no memperoleh F1 tertinggi dan kelas yes_implicit terendah pada setiap pengaturan kedua model. Seluruh pilihan *prompt* Qwen juga menghasilkan F1 yang lebih tinggi daripada XLM-R untuk ketiga kelas pada bahasa data yang sama.

Prompt dengan *macro-F1* tertinggi belum tentu terbaik pada setiap kelas. Pada data Inggris dan Italia, *prompt* Inggris tertinggi untuk no dan yes_implicit, sedangkan *prompt* Italia tertinggi untuk yes_explicit. Pada data Belanda, *prompt* Belanda tertinggi untuk no dan yes_explicit, sedangkan *prompt* Inggris tertinggi untuk yes_implicit.

Kelas yes_implicit tetap menjadi yang paling sulit. F1 Qwen pada kelas ini berada pada rentang 0,5397–0,6172 untuk data Inggris, 0,5815–0,6127 untuk data Italia, dan 0,4806–0,5094 untuk data Belanda, sedangkan XLM-R hanya memperoleh 0,4085, 0,4747, dan 0,3304. Nilai F1 belum menunjukkan ke kelas mana kesalahan diarahkan, sehingga pola kekeliruan perlu diperiksa langsung pada contoh prediksi.

6 Kesimpulan

Penyelesaian Subtask B StereoQueerEval menggunakan SFT LoRA pada Qwen3.5-9B menghasilkan skor lebih tinggi daripada XLM-R pada pengujian internal. Skor tertinggi adalah 0,719146 pada data Inggris, 0,7036 pada data Italia, dan 0,641522 pada data Belanda. Kesamaan bahasa *prompt* dan komentar belum konsisten memberikan hasil tertinggi. Pengembangan berikutnya perlu memperkuat klasifikasi yes_implicit dan memilih pengaturan melalui *validation*.

Keterbatasan

Percobaan menggunakan satu *seed* dan satu versi *prompt* per bahasa. Setiap pasangan Qwen melatih *adapter* terpisah, sehingga hasil tidak mengisolasi bahasa *prompt* pada satu model terlatih. Variasi antarpengulangan belum dinilai. Reproduksibilitas memerlukan kesamaan model dasar, *tokenizer*, data, *prompt*, dan konfigurasi LoRA. Hasil dapat berbeda lintas versi perangkat lunak atau GPU meskipun *seed* sama (PyTorch Contributors, 2026). Kestabilan hasil perlu diuji dengan beberapa *seed*.

References

Shabnam Behzad, Amir Zeldes, and Nathan Schneider. 2024. To ask LLMs about English grammaticality, prompt them in a different language. In *Findings of the Association for Computational Linguistics: EMNLP 2024*, pages 15622–15634, Miami, Florida, USA. Association for Computational Linguistics.

Fai Leui Chan, Duke Nguyen, and Aditya Joshi. 2024. "is hate lost in translation?": Evaluation of multilingual LGBTQIA+ hate speech detection. In *Proceedings of the 22nd Annual Workshop of the Australasian Language Technology Association*, pages 146–152, Canberra, Australia. Association for Computational Linguistics.

Alexis Conneau, Kartikay Khandelwal, Naman Goyal, Vishrav Chaudhary, Guillaume Wenzek, Francisco Guzmán, Edouard Grave, Myle Ott, Luke Zettlemoyer, and Veselin Stoyanov. 2020. Unsupervised cross-lingual representation learning at scale. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 8440–8451, Online. Association for Computational Linguistics.

Mai ElSherief, Caleb Ziems, David Muchlinski, Vaishnavi Anupindi, Jordyn Seybolt, Munmun De Choudhury, and Diyi Yang. 2021. Latent hatred: A benchmark for understanding implicit hate speech. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 345–363, Online and Punta Cana, Dominican Republic. Association for Computational Linguistics.

Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. 2021. LoRA: Low-rank adaptation of large language models. *Preprint*, arXiv:2106.09685.

Ilya Loshchilov and Frank Hutter. 2019. Decoupled weight decay regularization. In *International Conference on Learning Representations*.

Quoc-Toan Nguyen, Josh Nguyen, Van-Tuan Pham, and William John Teahan. 2025. Leveraging large language models in detecting anti-LGBTQIA+ user-generated texts. In *Proceedings of the Queer in AI Workshop*, pages 26–34, Hybrid format (in-person and virtual). Association for Computational Linguistics.

PyTorch Contributors. 2026. Reproducibility. Dokumentasi PyTorch, diakses 27 Oktober 2026.

Qwen Team. 2026. Qwen3.5-9B: Model card. Dokumentasi checkpoint resmi, diakses 25 Oktober 2026.

StereoQueerEval Organizers. 2026. StereoQueerEval: Official repository and training data documentation for SemEval 2027. Dokumentasi daring, diakses 25 Oktober 2026.

Unicode Consortium. 2026. Unicode Standard Annex #15: Unicode Normalization Forms. Revision 58, 12 August 2026; accessed 27 October 2026.