# StereoQueerEval: Klasifikasi Ujaran Kebencian terhadap Komunitas LGBTQIA+ dengan XLM-RoBERTa dan Qwen3.5-9B

**Anonymous ACL submission**


## Ringkasan

Penelitian ini menyajikan pendekatan untuk menyelesaikan Subtask B SemEval-2027 Task 8: StereoQueerEval, yaitu mengklasifikasikan komentar YouTube ke dalam kelas `no`, `yes_implicit`, dan `yes_explicit`. XLM-RoBERTa Base digunakan sebagai pembanding, sedangkan Qwen3.5-9B disesuaikan pada data berlabel menggunakan Low-Rank Adaptation (LoRA). Komentar dipertahankan dalam bahasa aslinya dan diproses tanpa judul serta deskripsi video. Evaluasi menggunakan data Inggris, Italia, dan Belanda dengan pembagian pelatihan, validasi, dan pengujian yang sama untuk kedua pendekatan. Pada Qwen, instruksi Inggris, Italia, dan Belanda digunakan sebagai pilihan pengaturan klasifikasi. Seluruh pengaturan Qwen memperoleh macro-F1 lebih tinggi daripada XLM-RoBERTa pada pengujian internal. Nilai Qwen tertinggi yang teramati adalah 0,715757 untuk Inggris, 0,7036 untuk Italia, dan 0,641522 untuk Belanda. Analisis per kelas menunjukkan bahwa kelas `yes_implicit` masih sulit dibedakan dari kelas lain. Hasil ini menggambarkan kemampuan pendekatan pada pengujian internal dan belum merupakan hasil evaluasi resmi shared task.


## 1 Pendahuluan

Deteksi ujaran kebencian tidak hanya berkaitan dengan pengenalan kata-kata kasar. Pesan yang menyerang kelompok tertentu juga dapat disampaikan melalui ungkapan tersirat yang membutuhkan pemahaman konteks. ElSherief et al. (2021) menjelaskan bahwa bahasa berkode dan ungkapan tidak langsung menjadi tantangan dalam mendeteksi ujaran kebencian yang disampaikan secara tidak langsung. Perbedaan cara penyampaian tersebut membuat model perlu mengenali maksud pesan, bukan hanya kata-kata yang muncul di dalamnya.

Chan et al. (2024) mengkaji deteksi ujaran kebencian terhadap komunitas LGBTQIA+ menggunakan GPT-3.5-turbo pada teks asli dan teks yang diterjemahkan ke bahasa Inggris. Penerjemahan memberikan hasil yang beragam; sebagian istilah slang dan ungkapan yang berkaitan dengan budaya tertentu tidak diterjemahkan dengan tepat. Temuan tersebut menjadi pertimbangan untuk mempertahankan bahasa asli komentar. Penelitian itu juga menyarankan penggunaan instruksi dalam bahasa data serta pengujian model lain. Saran tersebut menjadi salah satu dasar penyusunan instruksi klasifikasi dalam penelitian ini.

Penelitian ini berfokus pada penyelesaian *Subtask B: Hate Speech Classification* dalam SemEval-2027 Task 8: StereoQueerEval. Komentar berbahasa Inggris, Italia, dan Belanda dikelompokkan ke dalam kelas `no`, `yes_implicit`, dan `yes_explicit`. XLM-RoBERTa Base digunakan sebagai pembanding, sedangkan pendekatan utama menggunakan Qwen3.5-9B yang disesuaikan dengan data task. Keduanya dinilai pada komentar uji yang sama.

Penyelesaian task mencakup penyiapan data, pelatihan model, dan penentuan satu label untuk setiap komentar. Pada Qwen, definisi kategori diberikan melalui instruksi berbahasa Inggris, Italia, atau Belanda. Ketiga pilihan digunakan untuk menemukan pengaturan yang sesuai bagi klasifikasi, dengan tetap mempertahankan bahasa asli komentar. Hasil evaluasi dilaporkan berdasarkan bahasa data dan kelas, disertai analisis kesalahan untuk memperjelas bagian yang masih perlu diperbaiki.

## 2 Deskripsi Task

### 2.1 SemEval-2027 Task 8: StereoQueerEval

StereoQueerEval merupakan task identifikasi stereotip dan ujaran kebencian yang menargetkan komunitas LGBTQIA+.[1] Data berupa komentar YouTube yang disertai judul dan deskripsi video sebagai informasi konteks. Task ini mencakup deteksi ste-

[1] https://semeval.github.io/SemEval2027/tasks.html

reotip, klasifikasi ujaran kebencian, serta identifikasi target dan identitas LGBTQIA+ yang menjadi sasaran kebencian (StereoQueerEval Organizers, 2026).

Penelitian ini berfokus pada Subtask B. Setiap komentar diberi salah satu dari tiga label berikut:

- `no`: komentar yang tidak mengandung ujaran kebencian, termasuk komentar yang mendukung komunitas LGBTQIA+.
- `yes_implicit`: kebencian yang disampaikan secara tersirat atau tidak langsung.
- `yes_explicit`: kebencian yang dinyatakan secara langsung terhadap individu atau kelompok LGBTQIA+.

StereoQueerEval mencakup bahasa Inggris, Italia, Belanda, dan Persia. Percobaan ini menggunakan tiga bahasa pertama, yang selanjutnya disingkat EN, IT, dan NL. Masukan dibatasi pada teks komentar beserta penanda bahasa; judul, deskripsi video, dan anotasi dari subtask lain tidak digunakan untuk menentukan label.

### 2.2 Penelitian Terkait

Deteksi kebencian terhadap komunitas LGBTQIA+ telah dikaji dengan model klasifikasi maupun model bahasa besar. Nozza (2022) menggabungkan prediksi BERT, RoBERTa, dan HateBERT untuk mengenali homofobia dan transfobia pada komentar YouTube Inggris. QUEEREOTYPES menyediakan anotasi stereotip dan ujaran kebencian secara terpisah pada data Italia (Cignarella et al., 2024). Sementara itu, Nguyen et al. (2025) mengevaluasi lima model bahasa besar untuk mengenali teks anti-LGBTQIA+ tanpa pelatihan tambahan dan melaporkan bahwa kesalahan klasifikasi masih terjadi.

Chan et al. (2024) membandingkan GPT-3.5-turbo sebelum dan sesudah pelatihan pada data berlabel. Hasilnya mendukung penggunaan pelatihan untuk klasifikasi multibahasa, tetapi tugasnya menggunakan dua kelas dan weighted-F1. Penelitian ini membedakan tiga kelas dan menggunakan macro-F1, sehingga nilai kedua penelitian tidak dibandingkan secara langsung. XLM-RoBERTa dipilih sebagai pembanding karena prapelatihannya mencakup 100 bahasa (Conneau et al., 2020), sedangkan LoRA memungkinkan penyesuaian Qwen melalui sejumlah kecil parameter tambahan (Hu et al., 2021).

Pilihan bahasa instruksi juga perlu diperhatikan ketika menggunakan model multibahasa. Behzad et al. (2024) menemukan bahwa instruksi dalam bahasa berbeda dapat menghasilkan nilai yang berbeda pada penilaian tata bahasa Inggris. Temuan tersebut berasal dari tugas lain, sehingga menjadi pertimbangan untuk menguji pilihan instruksi, bukan bukti langsung tentang deteksi kebencian. Dalam penyelesaian StereoQueerEval ini, tiga bahasa instruksi digunakan pada tahap pelatihan dan pengujian Qwen.

## 3 Metode

### 3.1 Alur Klasifikasi

Setiap komentar diproses melalui penyiapan teks, pelatihan pada data berlabel, dan prediksi salah satu dari tiga kategori. XLM-RoBERTa mempelajari klasifikasi langsung dari teks komentar. Qwen menerima definisi kategori dan komentar dalam format percakapan, kemudian memilih jawaban yang mewakili label. Model dilatih secara terpisah untuk setiap bahasa data, sehingga data Inggris, Italia, dan Belanda tidak digabungkan selama pelatihan.

### 3.2 XLM-RoBERTa

XLM-RoBERTa merupakan model Transformer multibahasa yang dilatih menggunakan lebih dari 2 TB teks CommonCrawl dari 100 bahasa (Conneau et al., 2020). Varian Base digunakan sebagai pembanding dalam penelitian ini. Teks komentar diubah menjadi token, kemudian diproses untuk memperoleh representasi yang mempertimbangkan hubungan antarkata. Representasi tersebut diteruskan ke lapisan klasifikasi untuk memprediksi tiga kelas task.

Seluruh parameter XLM-RoBERTa dan lapisan klasifikasi diperbarui menggunakan data pelatihan. Pelatihan menggunakan bobot kelas yang dihitung dari jumlah contoh pada data pelatihan agar kelas yang lebih sedikit mendapat perhatian dalam perhitungan kesalahan. Model dengan macro-F1 validasi tertinggi digunakan untuk pengujian.

### 3.3 Klasifikasi Menggunakan Qwen3.5-9B

Qwen3.5-9B digunakan sebagai model bahasa yang menerima instruksi klasifikasi (Qwen Team, 2026). Model disesuaikan melalui *supervised fine-tuning* (SFT), yaitu pelatihan menggunakan komentar dan jawaban yang benar. Penyesuaian dilakukan dengan LoRA, yang mempertahankan bobot utama model dan memperbarui parameter tambahan berukuran kecil (Hu et al., 2021). Sekitar 0,48% dari

| Bahasa | Kelas | train | val | test |
|---|---|---|---|---|
| EN | no | 983 | 147 | 277 |
| EN | yes_implicit | 546 | 70 | 156 |
| EN | yes_explicit | 582 | 75 | 153 |
| EN | Total | 2111 | 292 | 586 |
| IT | no | 822 | 105 | 233 |
| IT | yes_implicit | 401 | 56 | 124 |
| IT | yes_explicit | 476 | 59 | 124 |
| IT | Total | 1699 | 220 | 481 |
| NL | no | 784 | 109 | 234 |
| NL | yes_implicit | 335 | 55 | 97 |
| NL | yes_explicit | 437 | 62 | 125 |
| NL | Total | 1556 | 226 | 456 |

Tabel 1: Jumlah komentar pada pembagian data menurut label kelas. train, val, dan test berarti pelatihan, validasi, dan pengujian.

parameter yang dimuat diperbarui selama pelatihan.

Instruksi menjelaskan ketiga kategori dan menegaskan bahwa penyebutan identitas LGBTQIA+ saja tidak cukup untuk menganggap komentar sebagai kebencian. Instruksi tersedia dalam bahasa Inggris, Italia, dan Belanda, tanpa contoh komentar berlabel. Jawaban yang diminta berupa satu angka: 0 untuk `no`, 1 untuk `yes_explicit`, dan 2 untuk `yes_implicit`. Teks komentar tetap menggunakan bahasa aslinya. Penanda bahasa dan komentar pada masukan tetap ditulis dalam bahasa Inggris untuk seluruh pilihan instruksi.

Pelatihan diarahkan pada jawaban yang benar, sedangkan instruksi dan komentar tidak dimasukkan ke perhitungan kesalahan pelatihan. Saat prediksi, model menghitung jumlah log probabilitas setiap pilihan jawaban beserta penanda akhirnya. Jawaban dengan skor tertinggi menjadi label prediksi. Dengan aturan ini, hasil selalu berupa salah satu dari tiga kategori dan tidak bergantung pada penjelasan bebas dari model.

# 4 Rancangan Eksperimen

## 4.1 Deskripsi Dataset

Data berjumlah 2.989 komentar Inggris, 2.400 Italia, dan 2.238 Belanda. Setiap bahasa dibagi menjadi bagian pelatihan, validasi, dan pengujian dengan perbandingan mendekati 70:10:20 dan seed 42. Pembagian mempertahankan kelompok komentar dengan konteks video yang sama serta komentar duplikat pada bagian yang sama. Kelompok konteks dikenali melalui pasangan judul dan deskripsi video. Karena kelompok tidak dipecah, jumlah akhir tidak selalu tepat mengikuti rasio tersebut.

Seluruh bagian berasal dari data pelatihan yang dirilis penyelenggara. Hasil yang dilaporkan merupakan pengujian internal, bukan pengujian resmi shared task. Data pelatihan digunakan untuk memperbarui parameter, data validasi untuk memilih hasil pelatihan terbaik, dan data pengujian untuk menghitung hasil akhir. Identitas serta label komentar uji yang digunakan kedua pendekatan telah diperiksa dan sama.

## 4.2 Analisis Eksplorasi Data

Tabel 1 menunjukkan bahwa kelas `no` memiliki jumlah terbesar pada setiap bagian data. Kelas `yes_implicit` dan `yes_explicit` lebih sedikit, sehingga ketepatan pada kelas terbanyak saja belum cukup untuk menggambarkan kemampuan model. Oleh karena itu, evaluasi menggunakan macro-F1 dan dilengkapi hasil setiap kelas. Jumlah data pelatihan juga berbeda antarbahasa; data Inggris paling banyak, diikuti Italia dan Belanda.

Pemeriksaan tidak menemukan ID yang sama, komentar yang sama setelah normalisasi, maupun pasangan judul–deskripsi nonkosong yang sama pada bagian berbeda. Meskipun demikian, pasangan judul–deskripsi hanya merupakan pendekatan untuk mengenali kelompok video, sehingga belum menjamin pemisahan identitas video secara sempurna.

## 4.3 Praproses Data

Praproses mengikuti pengaturan masing-masing pendekatan. Pada XLM-RoBERTa, huruf diseragamkan menjadi huruf kecil melalui *casefold* dan emoji diganti dengan penanda `[EMOJI]`. Pada Qwen, kapitalisasi, emoji, dan tanda baca dipertahankan. Komentar tidak diterjemahkan. Perbedaan praproses ini diperhitungkan ketika menafsirkan perbandingan kedua pendekatan.

Normalisasi Unicode NFKC, casefold, dan perapian spasi juga digunakan untuk memeriksa kesamaan komentar antarbagian data. Normalisasi untuk pemeriksaan tersebut tidak mengubah teks masukan Qwen. Sebelum tokenisasi, kelengkapan komentar, keunikan ID, dan kesesuaian label diperiksa. Masukan XLM-RoBERTa dibatasi hingga 384 token, sedangkan masukan Qwen hingga 1.024 token termasuk instruksi dan jawaban. Pada Qwen, komentar yang terlalu panjang dipotong dengan tetap menyediakan ruang untuk instruksi dan pilihan jawaban.

| Pengaturan | XLM-R | Qwen |
|---|---|---|
| Epoch maksimum | 10 | 5 |
| Learning rate | $10^{-5}$ | $10^{-4}$ |
| Batch efektif | 16 | 16 |
| Batas token | 384 | 1.024 |
| Weight decay | 0,01 | 0,01 |
| Penjadwalan | linear | cosine |
| Presisi | FP16 | BF16 |
| LoRA rank/alpha | – | 16/32 |
| LoRA dropout | – | 0,05 |

Tabel 2: Pengaturan pelatihan. Batch efektif adalah jumlah contoh per pembaruan parameter. Token merupakan satuan potongan teks yang diproses model.

### 4.4 Skenario Pelatihan Model

XLM-RoBERTa dilatih satu kali untuk setiap bahasa data, dengan memperbarui seluruh parameter. Qwen dilatih melalui SFT LoRA untuk sembilan pasangan bahasa data dan bahasa instruksi. Setiap pasangan dimulai dari model dasar yang sama dengan parameter LoRA baru. Instruksi yang dipilih dipertahankan pada pelatihan, validasi, dan pengujian. Dengan demikian, setiap pasangan memiliki hasil pelatihannya sendiri.

Sebagai pembanding tambahan, Qwen sebelum SFT dinilai dengan definisi kategori tanpa contoh berlabel atau pelatihan pada data task, yang disebut *zero-shot*. Hasil ini digunakan untuk menilai kemampuan model awal dibandingkan model setelah disesuaikan. Aturan pemilihan jawaban dipertahankan sama pada kedua tahap.

### 4.5 Konfigurasi Hyperparameter

Kedua pendekatan menggunakan AdamW (Loshchilov and Hutter, 2019), seed 42, dan evaluasi setiap akhir putaran pelatihan atau *epoch*. Pelatihan dihentikan lebih awal jika macro-F1 validasi tidak membaik dalam tiga evaluasi untuk XLM-RoBERTa atau dua evaluasi untuk Qwen. Hasil pelatihan terbaik dipilih berdasarkan macro-F1 validasi. Pengaturan utama disajikan pada Tabel 2.

Batch efektif Qwen terdiri atas empat komentar dengan akumulasi empat langkah. Qwen menggunakan pemanasan learning rate selama sekitar 5% dari rencana langkah pelatihan, sedangkan XLM-RoBERTa tidak menggunakan pemanasan. Pelatihan Qwen dijalankan pada NVIDIA H200 dan XLM-RoBERTa pada NVIDIA GeForce RTX 3060 Ti.

### 4.6 Metrik Evaluasi

Ukuran utama adalah macro-F1, yaitu rata-rata F1 dari tiga kelas dengan bobot yang sama. Precision menunjukkan proporsi prediksi suatu kelas yang benar, sedangkan recall menunjukkan proporsi contoh kelas tersebut yang berhasil dikenali. F1 menggabungkan precision dan recall sehingga dapat merangkum keduanya.

Sembilan hasil Qwen dilaporkan pada tabel utama. Hasil data EN dengan instruksi EN dan data IT dengan instruksi IT hanya memiliki nilai ringkasan tanpa rincian prediksi. Perbandingan Qwen sebelum dan sesudah SFT dibatasi pada tujuh pasangan dengan hasil pembanding. Nilai tertinggi pada data uji dilaporkan secara deskriptif; pemilihan pengaturan untuk pengujian berikutnya perlu menggunakan data validasi.

## 5 Hasil dan Pembahasan

### 5.1 Evaluasi dan Perbandingan Model

Tabel 3 menyajikan hasil klasifikasi pada data uji internal yang sama. XLM-RoBERTa memperoleh macro-F1 sebesar 0,484506 pada Inggris, 0,527877 pada Italia, dan 0,512953 pada Belanda. Seluruh pilihan instruksi Qwen setelah SFT menghasilkan nilai lebih tinggi daripada pembanding tersebut. Hasil ini mendukung penggunaan Qwen dengan LoRA sebagai pendekatan utama untuk penyelesaian task pada percobaan ini.

Perbandingan ini mencakup dua pendekatan dengan ukuran model, praproses, dan cara pelatihan yang berbeda. Oleh karena itu, selisih skor menggambarkan hasil keseluruhan pendekatan dan belum dapat dikaitkan hanya dengan arsitektur model atau penggunaan LoRA.

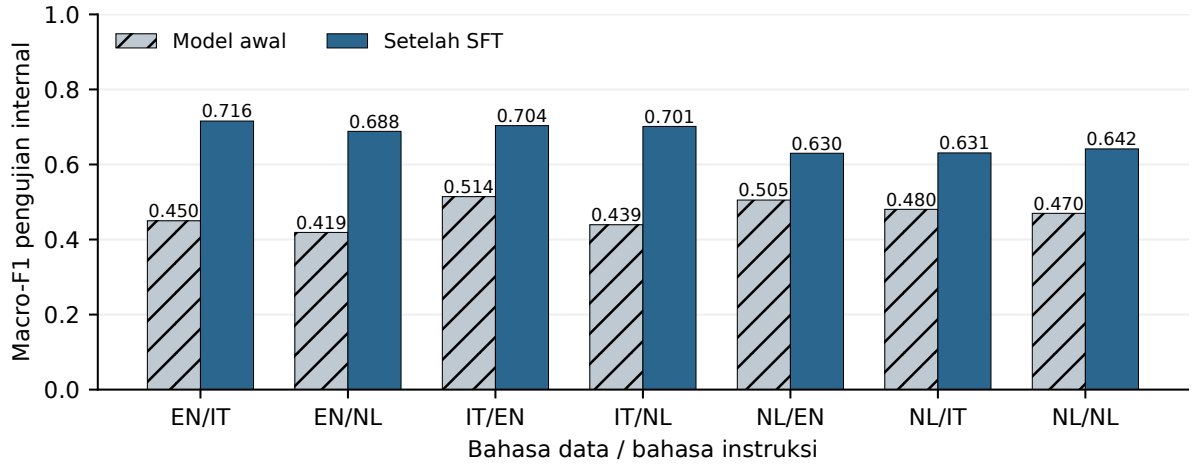
Pada tujuh pasangan dengan hasil zero-shot, SFT menghasilkan macro-F1 lebih tinggi daripada model awal, dengan kenaikan 12,47–26,94 poin pada skala F1 0–100 (Gambar 1). Sebagai contoh, data Inggris dengan instruksi Belanda meningkat dari 0,418932 menjadi 0,688340. Perbaikan setelah pelatihan berlabel juga dilaporkan oleh Chan et al. (2024), dengan tetap memperhatikan perbedaan data, model, jumlah kelas, dan ukuran evaluasi.

### 5.2 Analisis Kinerja Berdasarkan Bahasa

Pada data Inggris, macro-F1 Qwen berada pada rentang 0,688340–0,715757, sedangkan pada Italia berada pada rentang 0,701449–0,7036. Hasil Belanda berada pada rentang 0,629927–0,641522. Selisih tertinggi dan terendah pada Italia sekitar

| | | Qwen3.5-9B setelah SFT LoRA | | |
|---|---|---|---|---|
| Data | XLM-RoBERTa | Instruksi EN | Instruksi IT | Instruksi NL |
| EN | 0.484506 | 0.712664† | **0.715757** | 0.688340 |
| IT | 0.527877 | **0.7036** | 0.702038† | 0.701449 |
| NL | 0.512953 | 0.629927 | 0.630810 | **0.641522** |

Tabel 3: Macro-F1 pengujian internal. Cetak tebal menunjukkan nilai Qwen tertinggi pada setiap bahasa data. †: nilai hanya tersedia pada ringkasan hasil. Jumlah komentar uji: EN 586, IT 481, NL 456. Presisi angka Qwen mengikuti sumber hasil utama.




Gambar 1: Macro-F1 Qwen sebelum dan sesudah SFT pada pengujian internal. Label mendatar menunjukkan bahasa data/bahasa instruksi. Pasangan EN/EN dan IT/IT tidak disertakan karena nilai zero-shot belum tersedia.

0,0022, lebih kecil daripada Inggris sebesar 0,0274 dan Belanda sebesar 0,0116. Hasil Italia relatif berdekatan pada ketiga pilihan instruksi dalam percobaan ini.

Nilai tertinggi yang teramati diperoleh dengan instruksi Italia pada data Inggris, instruksi Inggris pada data Italia, serta instruksi Belanda pada data Belanda. Dengan demikian, kesamaan bahasa instruksi dan komentar belum memberikan hasil tertinggi secara konsisten. Pilihan instruksi perlu diperiksa pada data validasi untuk setiap bahasa data.

Pada Qwen, ketiga pilihan instruksi menghasilkan skor Belanda yang lebih rendah dibandingkan Inggris dan Italia. Namun, pola ini tidak sama pada XLM-RoBERTa, yang memperoleh skor terendah pada Inggris. Perbedaan jumlah data pelatihan dan isi komentar perlu dipertimbangkan; hasil tersebut belum cukup untuk menyatakan bahwa satu bahasa secara umum lebih sulit diklasifikasikan.

### 5.3 Analisis Kinerja Berdasarkan Kelas

Analisis berikut berfokus pada Qwen dengan instruksi Belanda pada ketiga bahasa data agar pilihan instruksi tetap sama. Tabel 4 menunjukkan bahwa F1 kelas `no` paling tinggi, sedangkan kelas `yes_implicit` paling rendah. F1 kelas `yes_implicit` mencapai 0,5397 pada Inggris, 0,6020 pada Italia, dan 0,4828 pada Belanda. Pembedaan komentar berlabel `yes_implicit` dari kelas lain menjadi bagian yang masih perlu diperbaiki dalam penyelesaian task.

Pada Italia, recall kelas `yes_implicit` mencapai 0,7258, tetapi precision hanya 0,5143. Artinya, banyak contoh kelas `yes_implicit` berhasil dikenali, namun komentar kelas lain juga keliru dimasukkan ke kategori ini. Pada Belanda, precision kelas `yes_implicit` sebesar 0,4148 menunjukkan persoalan serupa. Perbaikan perlu mencakup pengenalan komentar berlabel `yes_implicit` sekaligus pengurangan prediksi kelas `yes_implicit` yang keliru.

| Data | Kelas | Jumlah | Precision | Recall | F1 |
|---|---|---|---|---|---|
| EN | no | 277 | 0.8163 | 0.8339 | 0.8250 |
| EN | yes_implicit | 156 | 0.5346 | 0.5449 | 0.5397 |
| EN | yes_explicit | 153 | 0.7222 | 0.6797 | 0.7003 |
| IT | no | 233 | 0.8450 | 0.7253 | 0.7806 |
| IT | yes_implicit | 124 | 0.5143 | 0.7258 | 0.6020 |
| IT | yes_explicit | 124 | 0.7830 | 0.6694 | 0.7217 |
| NL | no | 234 | 0.8341 | 0.7949 | 0.8140 |
| NL | yes_implicit | 97 | 0.4148 | 0.5773 | 0.4828 |
| NL | yes_explicit | 125 | 0.7143 | 0.5600 | 0.6278 |

Tabel 4: Hasil setiap kelas pada Qwen dengan instruksi Belanda. Jumlah menunjukkan banyaknya komentar dengan label sebenarnya. Analisis menggunakan instruksi yang sama, bukan tiga pilihan dengan skor uji tertinggi.

### 5.4 Analisis Kesalahan Klasifikasi

Gambar 2 memperlihatkan kelas yang sering tertukar pada Qwen dengan instruksi Belanda. Terdapat 166 kesalahan dari 586 komentar Inggris, 139 dari 481 komentar Italia, dan 144 dari 456 komentar Belanda. Pada Inggris, 40 komentar berlabel `yes_implicit` diprediksi sebagai `no` dan 31 diprediksi sebagai `yes_explicit`. Kesalahan tersebut menunjukkan bahwa komentar berlabel `yes_implicit` masih tertukar dengan kedua kelas lainnya.

Pada Italia, 54 komentar berlabel `no` dan 31 komentar berlabel `yes_explicit` keliru diprediksi sebagai `yes_implicit`. Pada Belanda, kesalahan ke kelas `yes_implicit` berasal dari 41 komentar berlabel `no` dan 38 komentar berlabel `yes_explicit`. Pola ini membantu menjelaskan rendahnya precision kelas `yes_implicit` pada kedua bahasa.

Jumlah kesalahan belum menjelaskan penyebab pada masing-masing komentar. Pemeriksaan lanjutan dapat diarahkan pada ungkapan tidak langsung, negasi, kutipan, dan tanggapan yang menolak kebencian. Latent Hatred membahas ujaran kebencian yang disampaikan secara tidak langsung (ElSherief et al., 2021), sedangkan HateCheck menyediakan pengujian terarah untuk menemukan kelemahan klasifikasi kebencian (Röttger et al., 2021). Pemeriksaan tersebut belum dilakukan dalam percobaan ini.

## 6 Kesimpulan

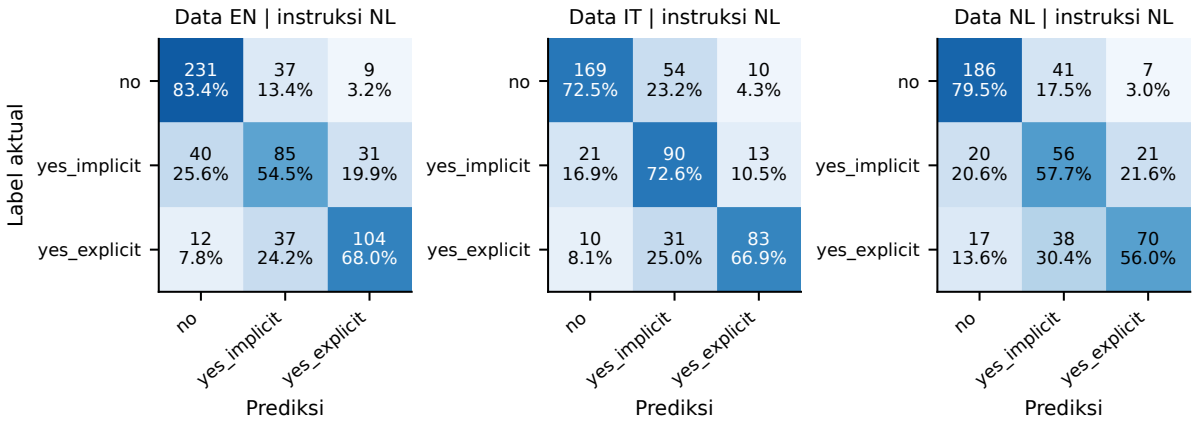
Penyelesaian Subtask B StereoQueerEval dilakukan dengan klasifikasi tiga kelas pada komentar Inggris, Italia, dan Belanda. XLM-RoBERTa Base digunakan sebagai pembanding, sedangkan pendekatan utama menyesuaikan Qwen3.5-9B dengan SFT LoRA. Seluruh pilihan instruksi Qwen memperoleh macro-F1 lebih tinggi daripada XLM-RoBERTa pada data uji internal yang sama. Nilai tertinggi yang teramati adalah 0,715757 pada Inggris, 0,7036 pada Italia, dan 0,641522 pada Belanda.

Pelatihan berlabel juga menghasilkan skor lebih tinggi daripada Qwen awal pada tujuh perbandingan yang tersedia. Meskipun demikian, kelas `yes_implicit` masih sering tertukar dengan kelas lain. Pengembangan berikutnya perlu memperkuat pembedaan kategori tersebut, mengulang percobaan dengan beberapa seed, dan memilih pengaturan berdasarkan data validasi sebelum pengujian lanjutan.

## Keterbatasan

Percobaan menggunakan satu seed dan satu versi instruksi per bahasa, sehingga konsistensi hasil pada pengulangan lain belum diketahui. Setiap pasangan bahasa Qwen memiliki adapter yang dilatih terpisah; hasilnya belum menunjukkan perbedaan bahasa instruksi pada satu model terlatih yang sama. Selain itu, praproses dan ukuran kedua model berbeda. Dua hasil Qwen hanya tersedia sebagai ringkasan, dan analisis per kelas dibatasi pada instruksi Belanda.

Data uji berasal dari pembagian internal data pelatihan penyelenggara. Hasil belum mencerminkan kinerja pada data uji resmi maupun platform dan topik lain. Penggunaan judul dan deskripsi video sebagai konteks tambahan serta pemeriksaan langsung komentar yang salah diklasifikasikan dapat dipertimbangkan pada pengembangan berikutnya.




Gambar 2: Matriks kesalahan Qwen dengan instruksi Belanda. Baris menunjukkan label sebenarnya dan kolom menunjukkan prediksi. Setiap sel memuat jumlah komentar dan persentasenya terhadap jumlah pada baris yang sama.

## References


Shabnam Behzad, Amir Zeldes, and Nathan Schneider. 2024. To ask LLMs about English grammaticality, prompt them in a different language. In *Findings of the Association for Computational Linguistics: EMNLP 2024*, pages 15622–15634, Miami, Florida, USA. Association for Computational Linguistics.

Fai Leui Chan, Duke Nguyen, and Aditya Joshi. 2024. "is hate lost in translation?": Evaluation of multilingual LGBTQIA+ hate speech detection. In *Proceedings of the 22nd Annual Workshop of the Australasian Language Technology Association*, pages 146–152, Canberra, Australia. Association for Computational Linguistics.

Alessandra Teresa Cignarella, Manuela Sanguinetti, Simona Frenda, Andrea Marra, Cristina Bosco, and Valerio Basile. 2024. QUEEREOTYPES: A multi-source Italian corpus of stereotypes towards LGBTQIA+ community members. In *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, pages 13429–13441, Torino, Italia. ELRA and ICCL.

Alexis Conneau, Kartikay Khandelwal, Naman Goyal, Vishrav Chaudhary, Guillaume Wenzek, Francisco Guzmán, Edouard Grave, Myle Ott, Luke Zettlemoyer, and Veselin Stoyanov. 2020. Unsupervised cross-lingual representation learning at scale. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 8440–8451, Online. Association for Computational Linguistics.

Mai ElSherief, Caleb Ziems, David Muchlinski, Vaishnavi Anupindi, Jordyn Seybolt, Munmun De Choudhury, and Diyi Yang. 2021. Latent hatred: A benchmark for understanding implicit hate speech. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 345–363, Online and Punta Cana, Dominican Republic. Association for Computational Linguistics.

Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. 2021. LoRA: Low-rank adaptation of large language models. *Preprint*, arXiv:2106.09685.

Ilya Loshchilov and Frank Hutter. 2019. Decoupled weight decay regularization. In *International Conference on Learning Representations*.

Quoc-Toan Nguyen, Josh Nguyen, Van-Tuan Pham, and William John Teahan. 2025. Leveraging large language models in detecting anti-LGBTQIA+ user-generated texts. In *Proceedings of the Queer in AI Workshop*, pages 26–34, Hybrid format (in-person and virtual). Association for Computational Linguistics.

Debora Nozza. 2022. Nozza@LT-EDI-ACL2022: Ensemble modeling for homophobia and transphobia detection. In *Proceedings of the Second Workshop on Language Technology for Equality, Diversity and Inclusion*, pages 258–264, Dublin, Ireland. Association for Computational Linguistics.

Qwen Team. 2026. Qwen3.5-9B: Model card. Dokumentasi checkpoint resmi, diakses 25 Oktober 2026.

Paul Röttger, Bertie Vidgen, Dong Nguyen, Zeerak Waseem, Helen Margetts, and Janet Pierrehumbert. 2021. HateCheck: Functional tests for hate speech detection models. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, pages 41–58, Online. Association for Computational Linguistics.

StereoQueerEval Organizers. 2026. StereoQueerEval: Official repository and training data documentation for SemEval 2027. Dokumentasi daring, diakses 25 Oktober 2026.