Ablasi Prapemrosesan, Konteks Video, dan Fungsi Loss untuk Deteksi Ujaran Kebencian LGBTQIA+ dengan Twitter-XLM-RoBERTa

Draf Penelitian
Identitas dan afiliasi penulis belum diisi

Ringkasan

Deteksi ujaran kebencian terhadap komunitas LGBTQIA+ memerlukan pembedaan antara komentar nonkebencian, kebencian implisit, dan kebencian eksplisit. Penelitian ini mengkaji pengaruh prapemrosesan, konteks video, pembobotan kelas, dan fungsi loss pada Twitter-XLM-RoBERTa untuk Subtask B StereoQueerEval. Rancangan mencakup delapan konfigurasi pada bahasa Inggris, Italia, dan Belanda, dengan model dilatih terpisah per bahasa. Dari 24 run yang direncanakan, tersedia 13 run lengkap: delapan Inggris dan lima Italia. Evaluasi menggunakan validation internal yang dipisahkan berdasarkan kelompok konteks dan duplikasi komentar. Konfigurasi terbaik sementara memperoleh macro-F1 0,6172 untuk Inggris dengan teks asli dan pembobotan kelas, serta 0,5794 untuk Italia dengan emoji dipertahankan dan teks di-casefold. Penambahan konteks video belum memperbaiki skor pada run yang tersedia. Recall kebencian implisit sebesar 0,6000 pada Inggris dan 0,3571 pada Italia menunjukkan perlunya diagnosis per kelas. Temuan bersifat deskriptif pada satu seed; hasil Belanda dan evaluasi test konfigurasi final belum tersedia dalam rangkaian ini.

1 Pendahuluan

Ujaran kebencian terhadap komunitas LGBTQIA+ dapat disampaikan melalui serangan langsung maupun ungkapan tidak langsung yang membutuhkan interpretasi konteks. ElSherief et al. (2021) menekankan tantangan bahasa kebencian implisit, termasuk makna diskriminatif yang disampaikan melalui bahasa tersandi atau implikasi. Dalam konteks queer, stereotip perlu dibedakan dari ujaran kebencian. QUEEREOTYPES menganotasi stereotip dan dimensi lain, termasuk hate speech, secara terpisah (Cignarella et al., 2024). Oleh sebab itu, keberadaan stereotip tidak dijadikan aturan otomatis untuk menetapkan label kebencian dalam penelitian ini.

Model bahasa pralatih menyediakan representasi kontekstual untuk klasifikasi teks. BERT menggunakan representasi bidireksional yang dapat disesuaikan untuk tugas hilir (Devlin et al., 2019), sedangkan XLM-R memperluas pembelajaran representasi ke banyak bahasa (Conneau et al., 2020). XLM-T melanjutkan arah tersebut pada data Twitter multilingual (Barbieri et al., 2022). Relevansi adaptasi register juga ditunjukkan oleh Wong et al. (2023), yang menguji pelatihan ulang XLM-R pada data media sosial untuk deteksi homofobia dan transfobia. Namun, kecocokan terhadap Twitter tidak dengan sendirinya menjamin keberhasilan pada komentar YouTube.

Penelitian ini menilai konfigurasi downstream pada satu backbone, yaitu Twitter-XLM-RoBERTa. Pertanyaan yang dikaji adalah bagaimana pelestarian emoji dan kapitalisasi, pembobotan kelas, konteks video, serta perubahan optimisasi memengaruhi macro-F1 validation. Kontribusinya berupa pelaporan ablasi yang dapat ditelusuri ke artefak eksperimen, perbandingan pola pada bahasa yang memiliki run lengkap, dan diagnosis kesalahan per kelas. Cakupan empiris dibatasi pada klasifikasi hate speech tiga kelas; deteksi stereotip dan identifikasi target belum dievaluasi.

2 Deskripsi Task

2.1 SemEval-2027 Task 8: StereoQueerEval

StereoQueerEval menyediakan komentar YouTube pada video berita bertopik LGBTQIA+, disertai judul dan deskripsi video (StereoQueerEval Organizers, 2026). Anotasinya meliputi stereotip, ujaran kebencian, dan target kebencian. Eksperimen ini memakai kolom `hate_speech`, dengan label `no`, `yes_implicit`, dan `yes_explicit`, yang berturut-turut menyatakan komentar nonkebencian, kebencian implisit, dan kebencian eksplisit. Kolom stereotip dan target tidak digunakan sebagai fitur.

Data yang disiapkan mencakup bahasa Inggris (EN), Italia (IT), dan Belanda (NL). Data Persia

tidak dilibatkan. Seluruh subset train, validation, dan test dalam naskah ini merupakan pembagian internal dari training release. Dengan demikian, test internal berbeda dari test resmi shared task. Naskah ini hanya melaporkan skor validation rangkaian ablasi.

2.2 Related Work

QUEEREOTYPES menyediakan korpus Italia dari Facebook dan Twitter untuk mengkaji stereotip terhadap komunitas LGBTQIA+, termasuk eksperimen klasifikasi dengan AlBERTo dan mBERT (Cignarella et al., 2024). Studi tersebut mendukung pemisahan stereotip dari dimensi kebencian, tetapi platform dan labelnya berbeda dari eksperimen ini. Sistem cantnlp menggunakan XLM-R yang dilatih ulang pada bahasa media sosial untuk klasifikasi homofobia dan transfobia dalam lima kondisi bahasa (Wong et al., 2023). Hasil kedua studi memberi dasar pemilihan model, tetapi tidak dapat dibandingkan langsung dengan skor StereoQueerEval.

Manfaat konteks eksternal perlu diuji secara empiris. Pavlopoulos et al. (2020) menemukan bahwa konteks dapat mengubah penilaian toksisitas manusia, tetapi tidak memperoleh bukti peningkatan kinerja classifier pada pengaturan yang diuji. Sebaliknya, Yu et al. (2022) melaporkan manfaat konteks komentar sebelumnya untuk klasifikasi hate speech dan counter speech pada Reddit. Konteks percakapan tersebut berbeda dari metadata video; hasilnya menjadi motivasi ablasi, bukan jaminan peningkatan.

Latent Hatred menekankan tantangan bahasa kebencian yang tidak langsung (ElSherief et al., 2021), sedangkan HateCheck menunjukkan bahwa skor agregat dapat menyembunyikan kelemahan fungsional model (Röttger et al., 2021). Karena itu, penelitian ini menyertakan precision, recall, F1 per kelas, dan confusion matrix. Pengujian fungsional untuk negasi, kutipan, atau counter speech belum dilakukan, sehingga fenomena tersebut tidak dinyatakan sebagai penyebab kesalahan yang telah teramati.

3 System Overview

3.1 Arsitektur Sistem Klasifikasi

Sistem terdiri atas prapemrosesan sesuai skenario, tokenisasi, encoder Twitter-XLM-RoBERTa, dan classification head tiga kelas. Model dimuat melalui `AutoModelForSequenceClassification`; encoder dan head disesuaikan pada data train. Prediksi dipilih berdasarkan logit tertinggi, tanpa threshold tambahan atau ensemble.

Pelatihan dilakukan terpisah untuk setiap bahasa dan konfigurasi. Encoder awal bersifat multilingual, tetapi data fine-tuning tidak digabung lintas bahasa. Pada skenario berkonteks, komentar menjadi urutan pertama dan metadata menjadi pasangan urutan kedua. Label validation digunakan untuk evaluasi dan pemilihan checkpoint, bukan sebagai fitur masukan.

3.2 Model Transformer

3.2.1 Twitter-XLM-RoBERTa-Base

Backbone yang dievaluasi adalah `cardiffnlp/twitter-xlm-roberta-base`, yang terkait dengan XLM-T (Barbieri et al., 2022). Model card menyatakan bahwa checkpoint ini dilatih pada sekitar 198 juta tweet multilingual.[1] Pemilihannya dimotivasi oleh paparan terhadap register media sosial. Penelitian ini tidak melanjutkan prapelatihan pada korpus YouTube; adaptasi dilakukan melalui fine-tuning berlabel.

3.2.2 XLM-RoBERTa-Base

XLM-R menggunakan prapelatihan masked language modeling multilingual pada data CommonCrawl (Conneau et al., 2020). Model ini relevan untuk menguji manfaat tambahan adaptasi Twitter. Namun, `FacebookAI/xlm-roberta-base` hanya menjadi opsi dalam notebook dan tidak aktif dalam daftar model rangkaian ablasi yang menjadi sumber naskah ini. Tidak ada keunggulan empiris XLM-T terhadap XLM-R yang disimpulkan.

3.2.3 Multilingual BERT Uncased

mBERT merupakan alternatif encoder multilingual berbasis BERT (Devlin et al., 2019). Varian `google-bert/bert-base-multilingual-uncased` mengabaikan perbedaan huruf besar dan kecil menurut model card-nya.[2] Model ini juga hanya menjadi opsi rancangan, bukan run aktif dalam sumber eksperimen. Analisis kapitalisasi di bawah merupakan perbandingan prapemrosesan pada Twitter-XLM-RoBERTa, bukan perbandingan dengan mBERT.

[1] https://huggingface.co/cardiffnlp/twitter-xlm-roberta-base

[2] https://huggingface.co/google-bert/bert-base-multilingual-uncased

Bahasa	Split	N	no	impl.	ekspl.
EN	train	2111	983	546	582
EN	val	292	147	70	75
EN	test	586	277	156	153
IT	train	1699	822	401	476
IT	val	220	105	56	59
IT	test	481	233	124	124
NL	train	1556	784	335	437
NL	val	226	109	55	62
NL	test	456	234	97	125

Tabel 1: Distribusi kelas per split internal. impl. dan ekspl. merujuk pada `yes_implicit` dan `yes_explicit`. Data NL telah disiapkan, tetapi hasil ablasinya belum tersedia.

4 Experimental Setup

4.1 Deskripsi dan Eksplorasi Dataset

Training release memuat 2.989 contoh EN, 2.400 IT, dan 2.238 NL. Pembagian internal menargetkan rasio 70:10:20 menggunakan seed 42. Catatan pembagian menyatakan penggunaan `StratifiedGroupKFold` dengan sepuluh fold yang dialokasikan sebanyak tujuh, satu, dan dua fold. Kelompok dibentuk dari kesamaan judul dan deskripsi ternormalisasi atau komentar duplikat, termasuk hubungan transitif. Karena kelompok tidak dipecah, rasio aktual tidak persis sama dengan target.

Tabel 1 menunjukkan bahwa no merupakan kelas terbesar di seluruh subset. Audit lokal mengonfirmasi tidak adanya overlap ID, komentar ternormalisasi, kelompok manifest, serta pasangan judul–deskripsi nonkosong antar-split. Normalisasi audit memakai NFKC, casefold, dan peringkasan whitespace. Proksi metadata ini mengurangi tumpang tindih konteks, tetapi tidak menjamin identitas video secara sempurna apabila metadata berubah atau identik untuk video berbeda.

4.2 Prapemrosesan Teks

E0 mengganti emoji pada komentar dengan teks literal `[EMOJI]` lalu menerapkan casefold. E1 mempertahankan emoji tetapi tetap memakai casefold. E2 menggunakan komentar asli tanpa kedua transformasi tersebut. Penggantian emoji E0 bukan penambahan special token baru ke vocabulary. Tidak ada stemming, penghapusan stopword, atau normalisasi URL/mention tambahan dalam fungsi tokenisasi notebook.

E3 menggunakan teks asli seperti E2 dan menghapus pembobotan kelas. E4 menambahkan judul video sebagai pasangan komentar. E5 menggunakan judul, pemisah titik, dan maksimal 200 karakter awal deskripsi. Batas 200 dihitung sebagai karakter sebelum tokenisasi, bukan token. E6 mempertahankan masukan E4 sambil mengubah learning rate dan warmup. E7 menggunakan komentar asli dengan focal loss tanpa pembobotan kelas.

Panjang maksimum adalah 384 token. Komentar tunggal memakai truncation biasa, sedangkan pasangan memakai `longest_first`, sehingga urutan yang lebih panjang dapat dipotong. Padding dilakukan secara dinamis per batch. Proporsi masukan yang terpotong belum tercatat; penurunan skor skenario berkonteks belum dapat dikaitkan langsung dengan truncation.

4.3 Proses Pelatihan Model

Optimisasi menggunakan AdamW (Loshchilov and Hutter, 2019) dengan scheduler linear dan weight decay 0,01. Evaluasi dilakukan setiap epoch. Model dengan macro-F1 validation tertinggi dimuat kembali untuk menghasilkan prediksi validation. Batas pelatihan sepuluh epoch, dengan early stopping setelah tiga evaluasi tanpa peningkatan. Notebook memakai seed 42 untuk inisialisasi dan urutan data, FP16, serta gradient checkpointing. Output perangkat mencatat NVIDIA GeForce RTX 3060 Ti.

Pada skenario berbobot, bobot dihitung hanya dari train sebagai $w_c = N/(3n_c)$, dengan n_c jumlah contoh kelas c dan N jumlah contoh train. Implementasinya memakai weighted cross-entropy. E3 menghilangkan bobot tersebut. E7 memakai focal loss untuk menurunkan kontribusi contoh yang telah diprediksi dengan mudah (Lin et al., 2017):

$$\mathcal{L}_{\text{focal}} = -\frac{1}{B}\sum_{i=1}^{B}(1 - p_{i,y_i})^2 \log p_{i,y_i}. \quad (1)$$

Di sini p_{i,y_i} adalah probabilitas kelas benar dan B ukuran batch. Tidak ada faktor pembobotan kelas tambahan pada E7. E7 dan E3 sama-sama menggunakan teks asli tanpa class weight, sehingga menjadi pasangan pembanding untuk perubahan loss.

4.4 Konfigurasi Hyperparameter

Ukuran batch train adalah 32, batch evaluasi 16, dan gradient accumulation satu langkah. Tabel 2 merangkum konfigurasi. E0–E5 dan E7 memakai learning rate 10^{-5} tanpa warmup. E6 menggunakan 2×10^{-5} dan warmup ratio 0,1. E6 terhadap E4

Run	Teks komentar	Konteks	Loss
E0	casefold, emoji diganti	–	WCE
E1	casefold, emoji asli	–	WCE
E2	asli	–	WCE
E3	asli	–	CE
E4	asli	judul	WCE
E5	asli	judul+deskripsi	WCE
E6	asli	judul	WCE*
E7	asli	–	focal

Tabel 2: Konfigurasi ablasi. WCE: weighted cross-entropy; CE: cross-entropy biasa. *E6 mengubah learning rate dan warmup. Semua run menggunakan satu seed.

	EN		IT	
Run	Macro-F1	Acc.	Macro-F1	Acc.
E0	0.5885	0.6336	0.5644	0.5955
E1	0.5955	0.6404	**0.5794**	0.6182
E2	**0.6172**	0.6541	0.5650	0.6091
E3	0.5886	0.6438	0.5507	0.6045
E4	0.5546	0.5856	0.5512	0.5727
E5	0.4667	0.5240	–	–
E6	0.5708	0.6130	–	–
E7	0.6104	0.6507	–	–

Tabel 3: Hasil validation; tebal menunjukkan macro-F1 tertinggi di antara run selesai per bahasa. Tanda – berarti belum tersedia. Tidak ada skor NL pada rangkaian ini.

mengubah dua parameter sekaligus, sehingga tidak mengisolasi kontribusi masing-masing.

Rancangan mencakup 24 run. Pada snapshot yang dianalisis, EN E0–E7 dan IT E0–E4 memiliki metrik lengkap. Output pelatihan terakhir berhenti dengan `KeyboardInterrupt` saat E5 Italia. IT E5–E7 dan seluruh run NL belum memiliki metrik lengkap di direktori rangkaian ini. Run yang belum lengkap tidak diberi skor nol atau diperlakukan sebagai hasil negatif.

4.5 Metrik Evaluasi

Metrik utama adalah macro-F1 atas tiga kelas:

$$F_{1,\text{macro}} = \frac{1}{3}\sum_{c=1}^{3} F_{1,c}, \quad F_{1,c} = \frac{2P_cR_c}{P_c + R_c}. \quad (2)$$

Precision P_c dan recall R_c dihitung per kelas; pembagian yang tidak terdefinisi ditetapkan nol sesuai implementasi evaluasi. Accuracy, weighted-F1, dan confusion matrix menjadi pelengkap. Macro-F1 memberi setiap kelas bobot yang sama dalam seleksi model.

Seluruh angka berikut berasal dari validation internal. Metrik dan confusion matrix dihitung ulang dari prediksi tersimpan dan dicocokkan dengan label validation. Validation yang sama digunakan untuk memilih epoch sekaligus konfigurasi, sehingga skor terbaik merupakan estimasi pengembangan yang berpotensi optimistis. Tidak dilakukan uji signifikansi atau estimasi variasi antar-seed.

5 Hasil dan Pembahasan

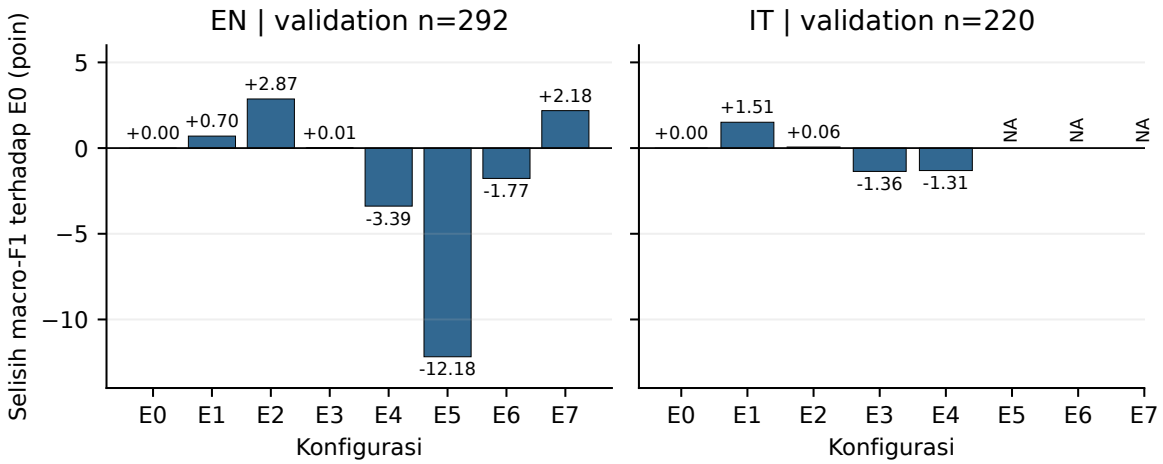
5.1 Evaluasi dan Perbandingan Model

Perbandingan pada Tabel 3 mencakup konfigurasi Twitter-XLM-RoBERTa yang selesai. EN terbaik diperoleh E2, dengan macro-F1 0,6172 dan accuracy 0,6541. Dibanding E0 (0,5885), peningkatan absolutnya 0,0287, atau 2,87 poin pada skala F1 0–100. E7 berada di bawah E2 dengan macro-F1 0,6104. Untuk IT, terbaik sementara adalah E1 dengan macro-F1 0,5794 dan accuracy 0,6182, dibandingkan E0 sebesar 0,5644. Keunggulan IT E1 hanya berlaku di antara E0–E4 yang selesai.

Gambar 1 menunjukkan bahwa perubahan prapemrosesan tidak berdampak seragam. Mempertahankan emoji (E1 versus E0) menaikkan macro-F1 sebesar 0,70 poin untuk EN dan 1,51 poin untuk IT. Mempertahankan kapitalisasi juga (E2 versus E1) menambah 2,17 poin pada EN, tetapi menurunkan 1,45 poin pada IT. Pola ini mendukung pemilihan konfigurasi per bahasa, dengan tetap mempertimbangkan ketidakpastian akibat satu seed dan validation yang kecil.

Penghapusan bobot kelas (E3 versus E2) menurunkan macro-F1 sebesar 2,86 poin pada EN dan 1,42 poin pada IT. Pada EN, focal loss E7 memperbaiki E3 sebesar 2,18 poin, tetapi masih berada 0,68 poin di bawah E2. Hasil tersebut mendukung pengujian lanjutan focal loss, tanpa cukup bukti untuk menggantikan weighted cross-entropy secara umum.

Penambahan judul (E4 versus E2) menurunkan macro-F1 sebesar 6,25 poin pada EN dan 1,37 poin pada IT. Pada EN, penambahan deskripsi juga menghasilkan skor 0,4667 pada E5, di bawah E4 sebesar 0,5546. E6 menaikkan skor EN terhadap E4 menjadi 0,5708, tetapi belum menyamai E2. Noise konteks, pemotongan token, atau perbedaan distribusi konteks merupakan kemungkinan penjelasan; eksperimen ini belum mengisolasi mekanismenya. Hasil tersebut menegaskan perlunya menguji bentuk konteks secara spesifik, sebagaimana perbedaan temuan studi sebelumnya (Pavlopoulos et al., 2020; Yu et al., 2022).



Gambar 1: Selisih macro-F1 validation terhadap E0 dalam poin pada skala 0–100. EN: 292 contoh; IT: 220 contoh. NA berarti run belum lengkap. Hasil berasal dari satu seed, sehingga tidak ditampilkan error bar. Nilai negatif menunjukkan skor lebih rendah daripada E0.

5.2 Analisis Kinerja Berdasarkan Bahasa

EN E2 memperoleh macro-F1 0,6172, sedangkan IT E1 memperoleh 0,5794. Selisih ini tidak cukup untuk menyimpulkan bahwa Italia secara intrinsik lebih sulit, karena ukuran train, isi komentar, dan konfigurasi terbaik berbeda. Pencarian IT juga belum selengkap EN. Bahkan pada konfigurasi yang sama, variasi data dan pelatihan tetap tidak terkontrol lintas bahasa.

EN E2 dipilih pada epoch ke-8 dan IT E1 pada epoch ke-9 menurut riwayat evaluasi. Weighted-F1 keduanya masing-masing 0,6541 dan 0,6135, lebih tinggi daripada macro-F1. Perbedaan ini menunjukkan perlunya melihat hasil per kelas. Untuk NL, data telah disiapkan, tetapi analisis kinerja menunggu run pada rangkaian yang sama; hasil notebook lain tidak dicampurkan ke tabel ini.

5.3 Analisis Kinerja Berdasarkan Kelas

Tabel 4 memperlihatkan hasil konfigurasi terbaik sementara. Kelas no memiliki F1 tertinggi pada kedua bahasa: 0,7619 untuk EN dan 0,7317 untuk IT. Pada EN, F1 implisit 0,5455 hampir sama dengan eksplisit 0,5441; tidak tepat menyatakan implisit selalu memiliki F1 terendah. Namun, precision implisit hanya 0,5000: separuh prediksi kelas ini sesuai dengan label gold.

Pada IT, F1 implisit 0,4124 lebih rendah daripada eksplisit 0,5942. Recall implisit 0,3571 berarti hanya 20 dari 56 contoh implisit dikenali dengan benar. Sebaliknya, 41 dari 59 contoh eksplisit dikenali, dengan recall 0,6949. Accuracy 0,6182 belum menggambarkan keberhasilan mengenali kebencian implisit secara memadai.

5.4 Analisis Kesalahan Klasifikasi

Gambar 2 merangkum arah kesalahan. EN E2 menghasilkan 101 kesalahan dari 292 komentar. Dari 70 contoh implisit, 18 diprediksi no dan 10 menjadi eksplisit. Dari 75 contoh eksplisit, 21 menjadi implisit dan 17 menjadi no. Sebaliknya, 35 dari 147 komentar no diprediksi sebagai salah satu kelas kebencian. Kebingungan mencakup batas kebencian/nonkebencian sekaligus pemisahan implisit/eksplisit.

IT E1 menghasilkan 84 kesalahan dari 220 komentar. Pada kelas implisit, 17 contoh diprediksi no dan 19 menjadi eksplisit. Sebanyak 30 dari 105 komentar no diprediksi hateful. Temuan ini mengidentifikasi kebutuhan meningkatkan cakupan deteksi implisit dan memeriksa false positive pada komentar nonkebencian.

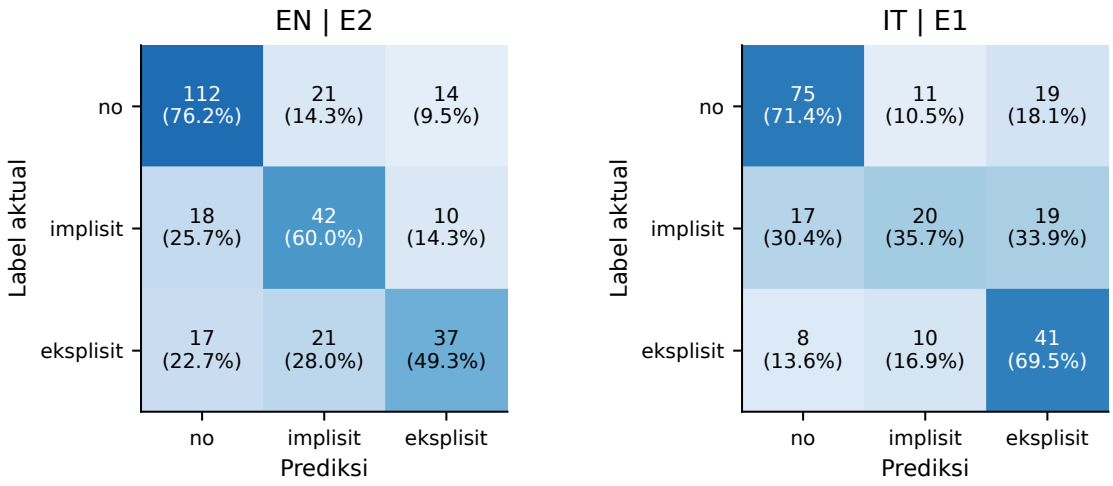
Confusion matrix tidak menjelaskan penyebab linguistik setiap kesalahan. Penelitian ini belum memberikan anotasi manual untuk ironi, negasi, kutipan, atau counter speech. Analisis dibatasi pada pasangan label yang teramati. Pengujian fungsional yang diinspirasi HateCheck (Röttger et al., 2021) dan pembacaan terarah atas kasus implisit (ElSherief et al., 2021) merupakan langkah lanjutan, bukan eksperimen yang telah selesai.

6 Kesimpulan

Ablasi Twitter-XLM-RoBERTa pada Subtask B StereoQueerEval menunjukkan perubahan kinerja validation terkait prapemrosesan dan pembobotan

Bahasa	Kelas	Support	Precision	Recall	F1
EN	no	147	0.7619	0.7619	0.7619
EN	implisit	70	0.5000	0.6000	0.5455
EN	eksplisit	75	0.6066	0.4933	0.5441
IT	no	105	0.7500	0.7143	0.7317
IT	implisit	56	0.4878	0.3571	0.4124
IT	eksplisit	59	0.5190	0.6949	0.5942

Tabel 4: Evaluasi per kelas pada validation untuk EN E2 dan IT E1. Support adalah jumlah contoh berlabel aktual. Checkpoint dipilih berdasarkan macro-F1.



Gambar 2: Confusion matrix validation untuk EN E2 ($N = 292$) dan IT E1 ($N = 220$). Baris: label aktual; kolom: prediksi. Setiap sel menampilkan jumlah dan persentase terhadap total baris; kedua panel memakai skala warna normalisasi baris yang sama.

kelas. Di antara 13 run selesai, EN terbaik memakai komentar asli dengan weighted cross-entropy (macro-F1 0,6172), sedangkan IT terbaik mempertahankan emoji dengan casefold dan loss berbobot (0,5794). Metadata video belum mengungguli komentar saja pada perbandingan yang tersedia. Recall implisit Italia yang rendah menegaskan perlunya evaluasi per kelas di samping skor agregat.

Kesimpulan dibatasi oleh satu seed, pemakaian validation untuk seleksi epoch dan konfigurasi, serta belum lengkapnya run Italia dan Belanda. Evaluasi test konfigurasi final belum tersedia pada rangkaian ini, dan manfaat adaptasi Twitter belum dibandingkan langsung dengan backbone lain. Penelitian lanjutan perlu menyelesaikan run tertunda, mengulang pelatihan dengan beberapa seed, mengukur truncation, dan mengevaluasi konfigurasi final pada test yang disisihkan. Naskah ini merupakan laporan pengembangan dari artefak tersimpan; hasilnya belum menjadi skor resmi shared task.

References

Francesco Barbieri, Luis Espinosa Anke, and Jose Camacho-Collados. 2022. XLM-T: Multilingual language models in Twitter for sentiment analysis and beyond. In *Proceedings of the Thirteenth Language Resources and Evaluation Conference*, pages 258–266, Marseille, France. European Language Resources Association.

Alessandra Teresa Cignarella, Manuela Sanguinetti, Simona Frenda, Andrea Marra, Cristina Bosco, and Valerio Basile. 2024. QUEEREOTYPES: A multisource Italian corpus of stereotypes towards LGBTQIA+ community members. In *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*, pages 13429–13441, Torino, Italia. ELRA and ICCL.

Alexis Conneau, Kartikay Khandelwal, Naman Goyal, Vishrav Chaudhary, Guillaume Wenzek, Francisco Guzmán, Edouard Grave, Myle Ott, Luke Zettlemoyer, and Veselin Stoyanov. 2020. Unsupervised cross-lingual representation learning at scale. In *Proceedings of the 58th Annual Meeting of the Association*

for Computational Linguistics, pages 8440–8451, Online. Association for Computational Linguistics.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. 2019. BERT: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 4171–4186, Minneapolis, Minnesota. Association for Computational Linguistics.

Mai ElSherief, Caleb Ziems, David Muchlinski, Vaishnavi Anupindi, Jordyn Seybolt, Munmun De Choudhury, and Diyi Yang. 2021. Latent hatred: A benchmark for understanding implicit hate speech. In *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, pages 345–363, Online and Punta Cana, Dominican Republic. Association for Computational Linguistics.

Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. 2017. Focal loss for dense object detection. In *Proceedings of the IEEE International Conference on Computer Vision*.

Ilya Loshchilov and Frank Hutter. 2019. Decoupled weight decay regularization. In *International Conference on Learning Representations*.

John Pavlopoulos, Jeffrey Sorensen, Lucas Dixon, Nithum Thain, and Ion Androutsopoulos. 2020. Toxicity detection: Does context really matter? In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 4296–4305, Online. Association for Computational Linguistics.

Paul Röttger, Bertie Vidgen, Dong Nguyen, Zeerak Waseem, Helen Margetts, and Janet Pierrehumbert. 2021. HateCheck: Functional tests for hate speech detection models. In *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, pages 41–58, Online. Association for Computational Linguistics.

StereoQueerEval Organizers. 2026. StereoQueerEval: Official repository and training data documentation for SemEval 2027. Dokumentasi daring, diakses 23 Oktober 2026.

Sidney Wong, Matthew Durward, Benjamin Adams, and Jonathan Dunn. 2023. cantnlp@LT-EDI-2023: Homophobia/transphobia detection in social media comments using spatio-temporally retrained language models. In *Proceedings of the Third Workshop on Language Technology for Equality, Diversity and Inclusion*, pages 103–108, Varna, Bulgaria. INCOMA Ltd., Shoumen, Bulgaria.

Xinchen Yu, Eduardo Blanco, and Lingzi Hong. 2022. Hate speech and counter speech detection: Conversational context does matter. In *Proceedings of the 2022 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, pages 5918–5930, Seattle, United States. Association for Computational Linguistics.